

Pandas

xbZhong

2024-08-19

[本页PDF](#)

数据读取

常用类型的读取

```
import pandas as pd
## 读取csv、tsv、txt数据
csv = pd.read_csv('path')

## 读取excel文件
excel = pd.read_excel('path')

## 读取sql文件
sql = pd.read_sql('path')

## 读取csv文件时index_col为0额可以忽略多余的索引列
reviews = pd.read_csv('../input/wine-reviews/winemag-data_first150k.csv', index_col = 0)
```

读取txt文件，自己指定分隔符、列名

```
txt = pd.read_csv(
    'path'
    # 指定分割字符
    sep = '\t'
    # 无标题行
    header = None
    # 自定义列名
    names = ['pdate', 'pv', 'uv']
)
```

常用操作

```
## 查看前几行数据
csv.head()
## 查看数据形状
csv.shape
## 查看列名列表
csv.columns
## 查看索引列
csv.index
## 查看每列的数据类型
csv.dtypes
```

导出文件

to_csv方法

```
## 将animals导出为csv
animals = pd.DataFrame({'Cows': [12, 20], 'Goats': [22, 19]}, index=['Year 1', 'Year 2'])
animals.to_csv('cows_and_goats.csv')
```

数据结构

- **Series**:一维数据，一行一列

```
## 自定义Series与index
s1 = pd.Series([1,'a',5.2,7],index=['d','b','a','c'])
ingredients = pd.Series(['4 cups','1 cup','2 large','1 can'],index = ['Flour','Milk','Eggs','Spam'],name = 'Dinner')
## 获取索引
s1.index

## 获取值
s1.values

## 根据index访问values
print(s1['a'])
print(type(s1['a']))
```

- **DataFrame**:二维数据，多行多列

```
## 查看列类型
df.dtypes
## 查看行索引
df.index
## 查看列索引
df.columns

## 查询一列，结果是Series
df['year']
## 查询多列，结果是DataFrame
df[['year','pop']]

## 查询第一行
df.loc[1]
## 查询多行(包含第三行，和python语法有差别)
df.locp[1:3]
```

创建DataFrame

```
import pandas as pd
fruits = pd.DataFrame({'Apple':[30],'Bananas':[21]})
```

数据类型

几种方法

```
## 查看每一列数据类型
reviews.dtypes
## 转换数据类型
reviews.points.astype('float64')
```

数据删除

- `drop(columns=['列名'])`

```
## 删除主键id的列
data = data.drop(columns=['主键id'])
```

- `drop_duplicates(subset = ['列1', '列2', ...], keep = 'first')`
 - 根据subset里面的列去重
 - keep: 控制如何保留重复值的哪一行, 常见的选项有:
 - first: 保留第一次出现的重复值
 - last: 保留最后一次出现的重复值
 - False: 删除所有重复项

```
df = df.drop_duplicates(subset=['监测点id', '监测时间', '企业DeptId'], keep='first')
```

数据查询

几种查询方法

`==.iloc`用数字索引左闭右开`==`

`==.loc`用数字索引左闭右闭`==`

```
## 根据行、列的标签值查询
df.loc
## 根据行、列的数字位置查询
df.iloc
```

`.loc`的几种查询方法

```
## 使用单个label的值来查询数据
df.loc['2018-01-03', 'bWendu']
## 使用值列表批量查询
df.loc[['2018-01-03', '2018-01-04', '2018-01-05'], ['bWendu', 'yWendu']]
## 使用数值区间进行查询
df.loc['2018-01-03': '2018-01-05', 'bWendu']
## 使用条件表达式查询
df.loc[df['yWendu'] <= 10, :]
```

用列名读取数据

```
## 属性值查询列
reviews.country
## 字典方式查询列
reviews['country']
## 查询特定值
reviews['country'][0]
```

补充方法

```
## isin方法查询country是Italy和France的行
reviews.loc[reviews.country.isin(['Italy', 'France'])] # 返回的是一行

## .idxmax()返回具有最大值元素的索引
(reviews.points / reviews.price).idxmax()
```

新增数据列

几种方法

```
## 直接赋值
df.loc[:, 'Wenchu'] = df['bWendu'] - df['yWendu']
## 使用apply方法
def get_wendu_type(x):
    if x['bWendu'] > 33:
        return '高温'
    if x['bWendu'] < -10:
        return '低温'
    return '常温'
df.loc[:, 'wendu_type'] = df.apply(get_wendu_type, axis = 1)
## assign方法, 不会修改原表, 返回的是新的表
df.assign(
    yWendu_huashi = lambda x : x['yWendu'] * 9 / 5 + 32,
    bWendu_huashi = lambda x : x['bWendu'] * 9 / 5 + 32
)
```

新增行

```
## 新增title行
reviews.set_index('title')
```

Pandas数据统计函数

1. 汇总类统计

```
## 提取所有数字列统计结果，非数字列也可以统计
df.describe()
## 平均值
df['bWendu'].mean()
## 最大值
df['bWendu'].max()
## 中位数
df['bWendu'].median()
```

2. 唯一去重和按值计数

```
## 得到不同类别(去重)
df['fengxiang'].unique()
## 根据不同类别计数
df['fengxiang'].value_counts()
```

3. 相关系数和协方差

```
## 协方差矩阵:衡量同向反向程度
df.cov()
## 相关系数矩阵:衡量相似程度
df.corr()
## 单独查看两变量的相关系数
df['api'].corr(df['bWendu'])
```

Pandas缺失值数据处理

检测是否是空值

```
## 查询整个DataFrame是否为空值
studf.isnull()
## 查询某个列是否为空值
studf['分数'].isnull()
## 与isnull相反
studf.notnull()
studf['分数'].notnull()
```

丢弃，删除缺失值

`dropna`：丢弃、删除缺失值

- axis：删除行还是列
- how：为any则任何值为空都删除，为all则所有值都为空才删除
- inplace：为True则修改当前df，否则返回新的df

```
## 删除全是空值的列
studf.dropna(axis = 1,how = 'all',inplace = True)
## 删除掉只要有空值的行
studf.dropna(axis = 0,how = 'any',inplace = True)
```

填充空值

fillna:填充空值

- value：用于填充的值，可以是字典或单个值
- method：填充方式,ffill为使用前一个不为空的值填充，bfill为使用后一个不为空的值填充
- axis：按行还是列填充
- inplace：为True修改当前df，否则返回新的df

```
## 将分数列为空的填充为0分
studf.fillna({'分数':0})
## 等同于
studf.loc[:, '姓名'] = studf.fillna(0)
## 将姓名的缺失值填充
studf.loc[:, '姓名'] = studf['姓名'].fillna(method = 'ffill')
```

替换

```
## 用replace方法把taster_twitter_handle列的@kerinokeefe替换为@kerino
reviews.taster_twitter_handle.replace("@kerinokeefe", "@kerino")
```

重命名和合并

重命名

rename

- index或columns：重命名行或列
- 用字典来实现
- inplace：为True表示在原DataFrame上进行修改

```
## 将列points改成score
reviews.rename(columns={'points': 'score'})
```

rename_axis

- 给行或列增加name属性
- name：name属性名字
- rows或columns：属性是在行索引还是列索引

```
## 给行索引添加name属性'wines'，给列索引添加name属性'fields'
reviews.rename_axis('wines',axis = 'rows').rename_axis('fields',axis = 'columns')
```

合并

concat 语法: `pandas.concat(objs,axis = 0, join = 'outer',ignore_index = False)`

- objs：一个列表，内容可以是 DataFrame 或者 Series
- axis：0为按行合并，1为按列合并

- `join`：合并时索引对齐方式，默认为outer,inner会过滤掉不匹配的列
- `ignore_index`：是否忽略掉原来的位置索引
- `concat`会自动匹配索引的值，但是没有定义的会填充NaN

```
## 合并
pd.concat([df1,df2])
## 按列合并
pd.concat([df1,df2],axis = 1)
```

join方法

- 根据索引自动匹配并合并值，未匹配成功的会丢弃
- `other`：要连接的另一个 DataFrame。
- `how`：连接方式，可以选择以下几种：
 - `'left'`：使用左边的 DataFrame 的索引，右边的 DataFrame 会填充 NaN。
 - `'right'`：使用右边的 DataFrame 的索引，左边的 DataFrame 会填充 NaN。
 - `'outer'`：保留两个 DataFrame 的所有索引，未匹配的地方填充 NaN。
 - `'inner'`：只保留索引匹配的行。
- `on`：指定用于连接的列（如果未设置为索引）。
- `lsuffix`：当两个 DataFrame 中存在重名列时，为左边 DataFrame 的列添加后缀。
- `rsuffix`：当两个 DataFrame 中存在重名列时，为右边 DataFrame 的列添加后缀。
- `sort`：是否根据连接后的索引排序，默认为 False。

```
DataFrame.join(other, how='left', on=None, lsuffix='', rsuffix='', sort=False)
## 根据两个DataFrame的MeetID进行合并
powerlifting_combined = owerlifting_meets.set_index('MeetID').join(powerlifting_competitors.set_index('MeetID'))
```

映射

map

```
## 求得points列的绝对值，用map定义lambda函数自减，p指的是reviews自己
review_points_mean = reviews.points.mean()
reviews.points.map(lambda p: p - review_points_mean)
## 计算description列中tropical和fruity出现的次数
descriptor_counts = pd.Series([reviews.description.map(lambda x : 'tropical' in x).sum(),reviews.description.map(lambda y: 'fruity' in y).sum()
()],index = ['tropical','fruity'])
```

apply

- axis为columns表示

```

## 可以用于行
def remean_points(row):
    row.points = row.points - review_points_mean
    return row

reviews.apply(remean_points, axis='columns')
## 定义函数，将row中的country为Canada的星级设为3颗星，然后根据分数来评星级
def method(row):
    if row.country == 'Canada':
        return 3
    elif row.points >= 95:
        return 3
    elif row.points >= 85:
        return 2
    return 1

star_ratings = reviews.apply(method,axis = 'columns')

## Check your answer
q7.check()

```

数据分组及排序

分组

groupby分组

```

## 按照points进行分组并对points进行数量计算，具有相同points的行会被分到同一组
reviews.groupby('points').points.sum()
## 可以接受多个参数并使用.apply()方法
reviews.groupby(['country', 'province']).apply(lambda df: df.loc[df.points.idxmax()])

## 按照price来分组，选取最大的points并按照points来排序
best_rating_per_price = reviews.groupby('price')['points'].max().sort_index()

```

agg方法

- 参数为一个列表，里面的元素是要调用的函数

```

## 可以接收多个参数，运行一系列不同的函数
reviews.groupby(['country']).price.agg([len, min, max])

```

多索引问题

```

## 转换回单索引，但前面的多索引会变成新的列
countries_reviewed.reset_index()

```

排序

- ascending：默认为True升序排序，为False降序排序
- inplace：是否替换原始Series
- by：按照哪一列进行排序，可以接收一个列表


```
## 按值进行排序
df['tianqi'].sort_values()
## 按照len列进行排序
countries_reviewed.sort_values(by='len')
## 接受一个列表进行排序
countries_reviewed.sort_values(by=['country', 'len'])
## 按索引进行排序
countries_reviewed.sort_index()
```