Transformer

xbZhong

2025-06-28

本页PDF

Transformer

是**Sequence to Sequence Model**的一种

编码器解码器架构作用：**让编码器全面理解输入序列的语义，并将其压缩为高阶表示（Context），解码器则基于此上下文信息，逐步生成目标序列**

输入部分细节

1. **Word Embedding（词向量嵌入）**

- 把输入的每个词（一个ID）转换成一个向量，比如 512维。
- 使用可学习的 `nn.Embedding` 层实现。

2. **Positional Encoding（位置编码）**

- 因为 Transformer 不像 **RNN** 有顺序结构，所以必须**显式**加入**位置信息。**
- 分两种方式：
  - 原始论文用的是**固定的正余弦函数**
  - 现在大多数用的是**可学习的位置向量**

Encoder模块细节

一个 Encoder 包括多个重复的子层，即**block块**（通常是 6 层）：

每层（个block）包含两个子模块：

1. **多头注意力机制（Multi-Head Self Attention）**
   - 输入之间相互看 → 比如“我 爱 学习”，每个词都看整个句子
2. **前馈神经网络（Feed Forward Network）**
   - 每个词单独处理，升维、激活、降维，类似 MLP
   - 小型的全连接网络

每个子模块后都有：

- **残差连接**
- **Layer Normalization**

Decoder部分细节

作用：产生输出

- 会把上一个时间节点的输出当作当前时间节点的输入
- 是**Auto-regressive**（自回归）类型

基本构成

每一层 Decoder 包含 **3 个子层 + 残差连接 + LayerNorm**：

- **已生成的词**作为带掩码自注意力的输入，要进行**位置编码**和**词向量生成**，且**解码器的输入是随着解码器的输出不断变化的**
- 经过**编码器处理过的输入和带掩码自注意力的输出**作为多头注意力的输入

1. **Masked Multi-Head Self-Attention（带掩码的自注意力）**
    - 作用：让每个位置的词只能“看到自己和前面的词”
    - 用法：防止 Decoder 在训练时“看到未来词”， 屏蔽未来信息
2. **Encoder-Decoder Attention（跨模块注意力）**
    - 作用：让 Decoder 能看到 Encoder 编码过的输入序列
    - **Query 来自 Decoder，Key 和 Value 来自 Encoder 的输出**。
    - 让 Decoder 能“参考”输入句子的语义信息，这样就可以用注意力机制让 Decoder“参考”输入句子，在生成翻译/回答/续写时更合理
3. **Feed Forward Network（前馈神经网络）**
    - 结构：两个全连接层 + 激活函数（**ReLU/GeLU**）、
4. **残差连接 + LayerNorm**

    每个子层后都加：

    - 残差连接：`output = input + Sublayer(input)`
    - LayerNorm：保持训练稳定、收敛更快

- **最后输出的矩阵只有第n行会用来预测下一个词**

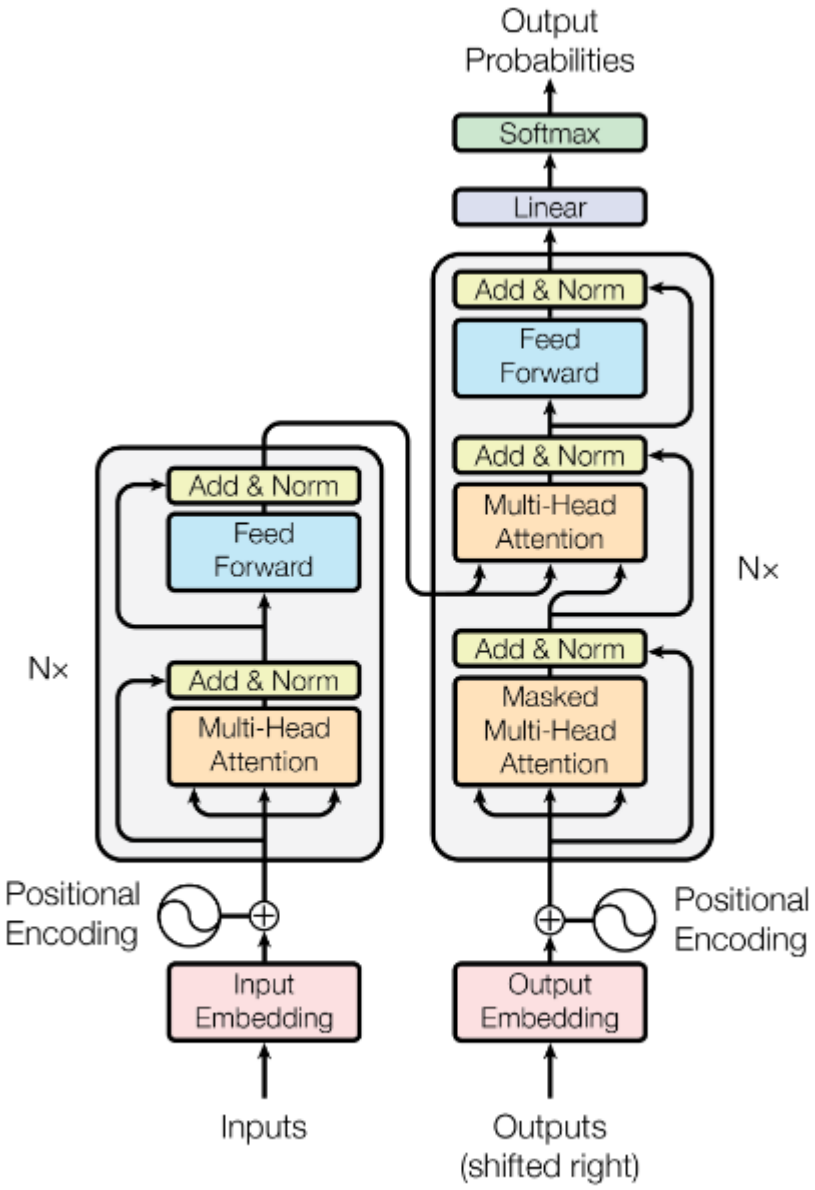

Figure 1: The Transformer - model architecture.

image-20250702225431058

Train（训练细节）

1. **Encoder：**
   - 接收输入序列（如英文句子），编码成一系列上下文相关的向量
   - 每个向量代表一个词的语义信息（包含上下文）
2. **Decoder：**
   - 输入目标序列（如中文句子）中前面的**真实词**（即 label 中已知的部分）
   - 每一步预测下一个词（比如预测“我 爱 ___”里的“你”）
3. **Teacher Forcing：**

- 在训练阶段，模型每一步的输入**直接使用真实目标序列中的token（即“正确答案”）**，而不是模型自己生成的token
- 训练时，Decoder 不用自己的输出作为下一步输入
- 而是用真实的上一个词， 快速学习，避免误差累积

Attention细节

- **Decoder 内部的 Self-Attention： Mask** 住后面的词，防止模型看到答案（实现自回归）
- **Encoder-Decoder Attention：** Decoder 的每一层都会“参考” Encoder 输出的语义向量，来帮助自己理解输入句子的含义

损失函数

- **每个位置的输出 → softmax → 得到一个词的概率分布**
- 与真实词的 one-hot 编码做对比 → 使用 **Cross Entropy Loss**

优化目标

使所有预测位置的交叉熵损失最小化

即：模型学会尽可能接近地预测出目标句子中的每一个词。

Teaching Forcing

训练时，Decoder 是可以看到“前面的正确答案”的，但不能看到“当前或未来的词”。这个技巧叫做 `Teacher Forcing`（教师强制）。

训练 Decoder 的时候：

- 模型生成第一个词的时候，输入 `<BOS>`（开始符）
- 第二个词用 **真实的第一个词**（比如“我”）作为输入
- 第三个词用**真实的**“我 爱”
- …直到句尾

而 **不是** 用模型上一步自己预测的词作为下一步的输入。

这种做法就叫 **Teacher Forcing**。

Residual Connection（残差连接）

基本原理

它将层的输入直接加到该层的输出上，形成“捷径”或“跳跃连接”。如果一个层的输入是x，输出是F(x)，则残差连接后的最终输出是x + F(x)

缓解梯度消失

- 如果一个层的输出是 $y = F(x) + x$（残差连接）
- 那么反向传播时，梯度 ∂L/∂x 可以分解为两部分：

$$\frac{\partial L}{\partial y} \cdot \frac{\partial y}{\partial x} = \frac{\partial L}{\partial y} \cdot (\frac{\partial F(x)}{\partial x} + 1)$$

- 即使 $\frac{\partial F(x)}{\partial x}$ 很小，加上1后仍能保证**有效的梯度传递**

Layer Normalization

它是做**标准化**的，避免不同样本间分布不稳定。

- **与 BatchNorm 不同**，它对的是**一个样本内部的所有特征归一化**，而不是整批样本。
- 在 NLP 序列建模中比 BatchNorm 更合适（因为样本长度不固定、batch 大小可能很小）
- **Layer Normalization**是对同一个**feature**不同的**dimension**进行归一化，**Batch Normalization**是对不同的**feature**的同一个**dimension**进行归一化

Explanation

给定四个词，下面展示**self-attention的计算过程**

单头注意力

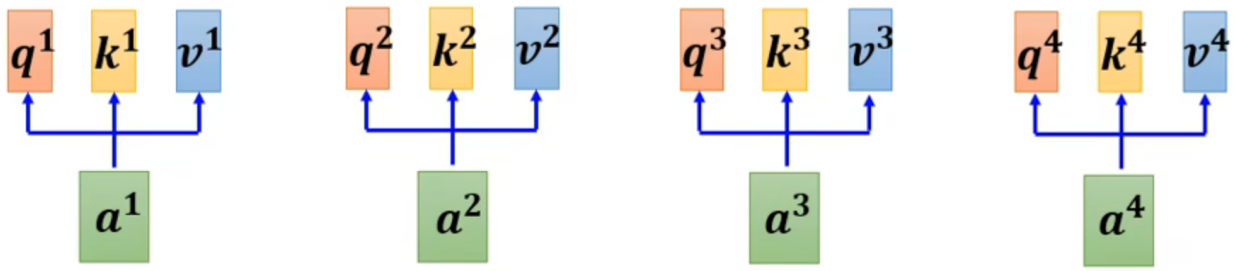

image-20250427121123206

1. 对输入进行**词嵌入**，加上**位置编码**得到a^1, a^2, a^3, a^4
2. 计算查询向量、键向量、值向量：

$$Q = \begin{bmatrix} q^1 \\ q^2 \\ q^3 \\ q^4 \end{bmatrix} = \begin{bmatrix} a^1 \\ a^2 \\ a^3 \\ a^4 \end{bmatrix} W^q$$

$$K = \begin{bmatrix} k^1 \\ k^2 \\ k^3 \\ k^4 \end{bmatrix} = \begin{bmatrix} a^1 \\ a^2 \\ a^3 \\ a^4 \end{bmatrix} W^k$$

$$V = \begin{bmatrix} v^1 \\ v^2 \\ v^3 \\ v^4 \end{bmatrix} = \begin{bmatrix} a^1 \\ a^2 \\ a^3 \\ a^4 \end{bmatrix} W^v$$

2. 计算**attention score**

$$A=\begin{bmatrix}\alpha_{1,1} & \alpha_{1,2} & \alpha_{1,3} & \alpha_{1,4}\\ \alpha_{2,1} & \alpha_{2,2} & \alpha_{2,3} & \alpha_{2,4}\\ \alpha_{3,1} & \alpha_{3,2} & \alpha_{3,3} & \alpha_{3,4}\\ \alpha_{4,1} & \alpha_{4,2} & \alpha_{4,3} & \alpha_{4,4}\end{bmatrix}=Q\cdot K^T$$

$$=\begin{bmatrix}q^1\\ q^2\\ q^3\\ q^4\end{bmatrix}\cdot\begin{bmatrix}k^1 & k^2 & k^3 & k^4\end{bmatrix}$$

3. 经过$\sqrt{d_k}$放缩作**softmax**，d_k为每个$key/querey$向量的维度大小

$$\text{输入矩阵 } A \xrightarrow{\text{softmax}} \text{输出矩阵 } A^{'}$$

$$\frac{1}{\sqrt{d_k}}\begin{bmatrix}\alpha_{1,1} & \alpha_{1,2} & \alpha_{1,3} & \alpha_{1,4}\\ \alpha_{2,1} & \alpha_{2,2} & \alpha_{2,3} & \alpha_{2,4}\\ \alpha_{3,1} & \alpha_{3,2} & \alpha_{3,3} & \alpha_{3,4}\\ \alpha_{4,1} & \alpha_{4,2} & \alpha_{4,3} & \alpha_{4,4}\end{bmatrix}\Rightarrow\begin{bmatrix}\alpha^{'}_{1,1} & \alpha^{'}_{1,2} & \alpha^{'}_{1,3} & \alpha^{'}_{1,4}\\ \alpha^{'}_{2,1} & \alpha^{'}_{2,2} & \alpha^{'}_{2,3} & \alpha^{'}_{2,4}\\ \alpha^{'}_{3,1} & \alpha^{'}_{3,2} & \alpha^{'}_{3,3} & \alpha^{'}_{3,4}\\ \alpha^{'}_{4,1} & \alpha^{'}_{4,2} & \alpha^{'}_{4,3} & \alpha^{'}_{4,4}\end{bmatrix}$$

4. 计算与值向量加权求和的值

$$[b^1,b^2,b^3,b^4]=\begin{bmatrix}\alpha^{'}_{1,1} & \alpha^{'}_{1,2} & \alpha^{'}_{1,3} & \alpha^{'}_{1,4}\\ \alpha^{'}_{2,1} & \alpha^{'}_{2,2} & \alpha^{'}_{2,3} & \alpha^{'}_{2,4}\\ \alpha^{'}_{3,1} & \alpha^{'}_{3,2} & \alpha^{'}_{3,3} & \alpha^{'}_{3,4}\\ \alpha^{'}_{4,1} & \alpha^{'}_{4,2} & \alpha^{'}_{4,3} & \alpha^{'}_{4,4}\end{bmatrix}\cdot\begin{bmatrix}v^1\\ v^2\\ v^3\\ v^4\end{bmatrix}$$

即

$$Attention(Q.K,V)=softmax(\frac{QK^T}{\sqrt{d_k}})V$$

多头注意力

如下图所示：会使用多的矩阵去作变换，如$W^{q,1},W^{q,2}$

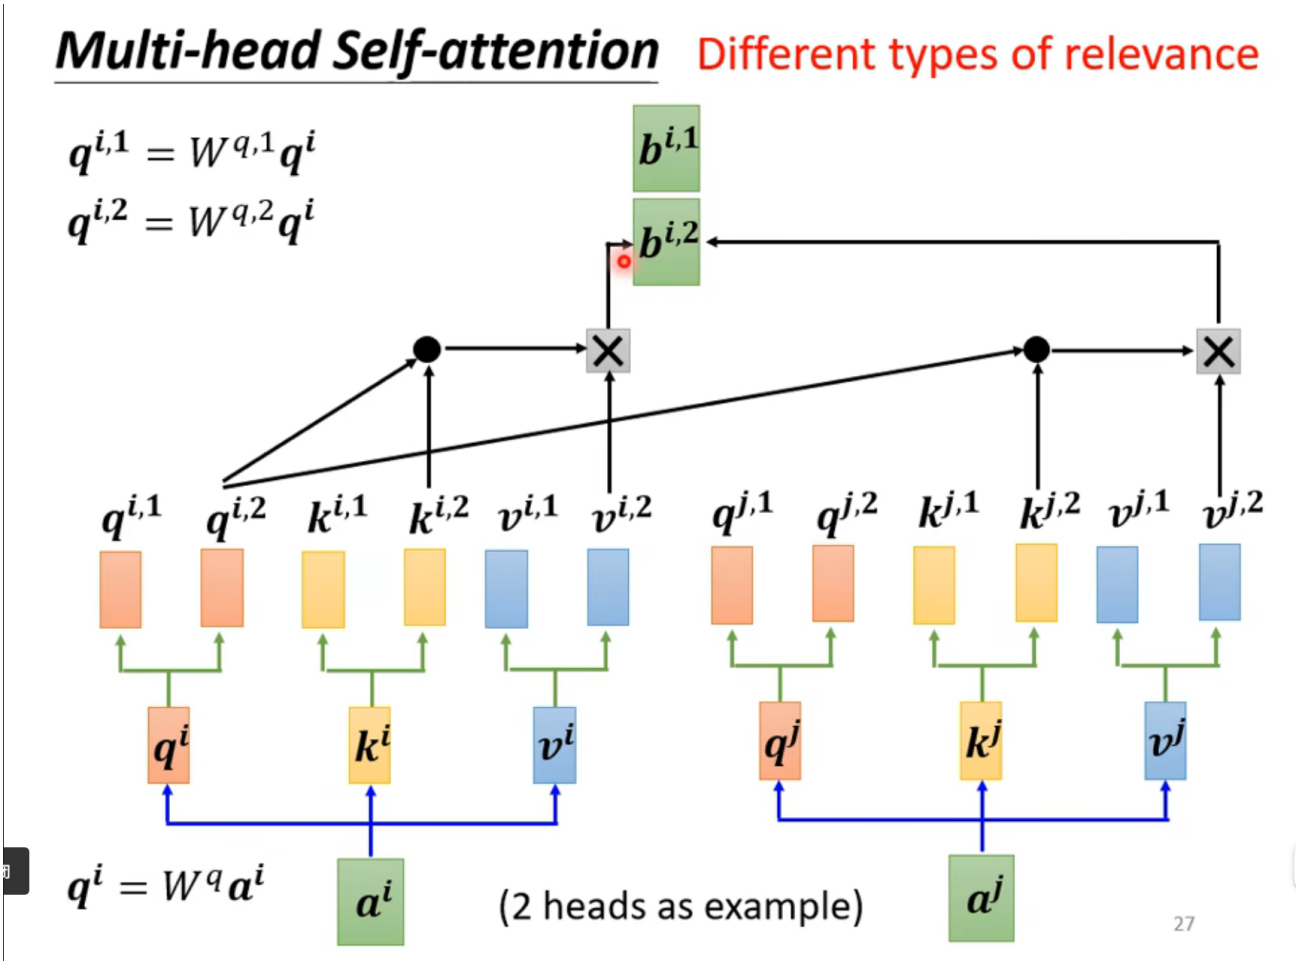

image-20250510194255934

以四个词，两个头为例，下面来展示计算过程

- 对于四个词向量a^i, a^j, a^m, a^n，可以用W^q、W^k、W^v**先计算出全局查询的查询、键、值向量**，Q、K、V
- 其中：W^q、W^k、W^v为**全局权重矩阵**

$$Q = \begin{bmatrix} a^i \\ a^j \\ a^m \\ a^n \end{bmatrix} W^q K = \begin{bmatrix} a^i \\ a^j \\ a^m \\ a^n \end{bmatrix} W^k V = \begin{bmatrix} a^i \\ a^j \\ a^m \\ a^n \end{bmatrix} W^v$$

- 然后进行**多头拆分**：

！！要注意的是多头拆分也可以**直接通过全局矩阵**Q、K、V**进行分割**

$$\begin{aligned} Q_1 &= QW^{q,1} \quad Q_2 = QW^{q,2} \\ K_1 &= KW^{q,1} \quad K_2 = KW^{q,2} \\ V_1 &= VW^{q,1} \quad V_2 = VW^{q,2} \end{aligned}$$

- **可得出表达式**

$$Q_1 = \begin{bmatrix} q^{i,1} \\ q^{j,1} \\ q^{m,1} \\ q^{n,1} \end{bmatrix} \quad Q_2 = \begin{bmatrix} q^{i,2} \\ q^{j,2} \\ q^{m,2} \\ q^{n,2} \end{bmatrix}$$

$$K_1 = \begin{bmatrix} k^{i,1} \\ k^{j,1} \\ k^{m,1} \\ k^{n,1} \end{bmatrix} \quad K_2 = \begin{bmatrix} k^{i,2} \\ k^{j,2} \\ k^{m,2} \\ k^{n,2} \end{bmatrix}$$

$$V_1 = \begin{bmatrix} v^{i,1} \\ v^{j,1} \\ v^{m,1} \\ v^{n,1} \end{bmatrix} \quad V_2 = \begin{bmatrix} v^{i,2} \\ v^{j,2} \\ v^{m,2} \\ v^{n,2} \end{bmatrix}$$

- 接着计算**每个头**的注意力

$$head_1 = softmax(\frac{Q_1 K_1^T}{\sqrt{d_k}})V_1 head_2 = softmax(\frac{Q_2 K_2^T}{\sqrt{d_k}})V_2$$

- **合并**多头输出

$$multihead = [head_1 \quad head_2]$$

- 最后进行**投影**

$$output = multihead \cdot W^O$$

Self-attention

适用于多向量输入的情形，且输入向量之间是有联系的

因此不能用**FC**作为训练模型，**FC忽略了向量之间的联系**，训练效果会很差

Sequence Labeling（输出输入一对一）

工作示例图：

- 自注意力机制考虑了所有输入向量，然后把整个考虑的结果输出成一个向量给到**FC**进行训练

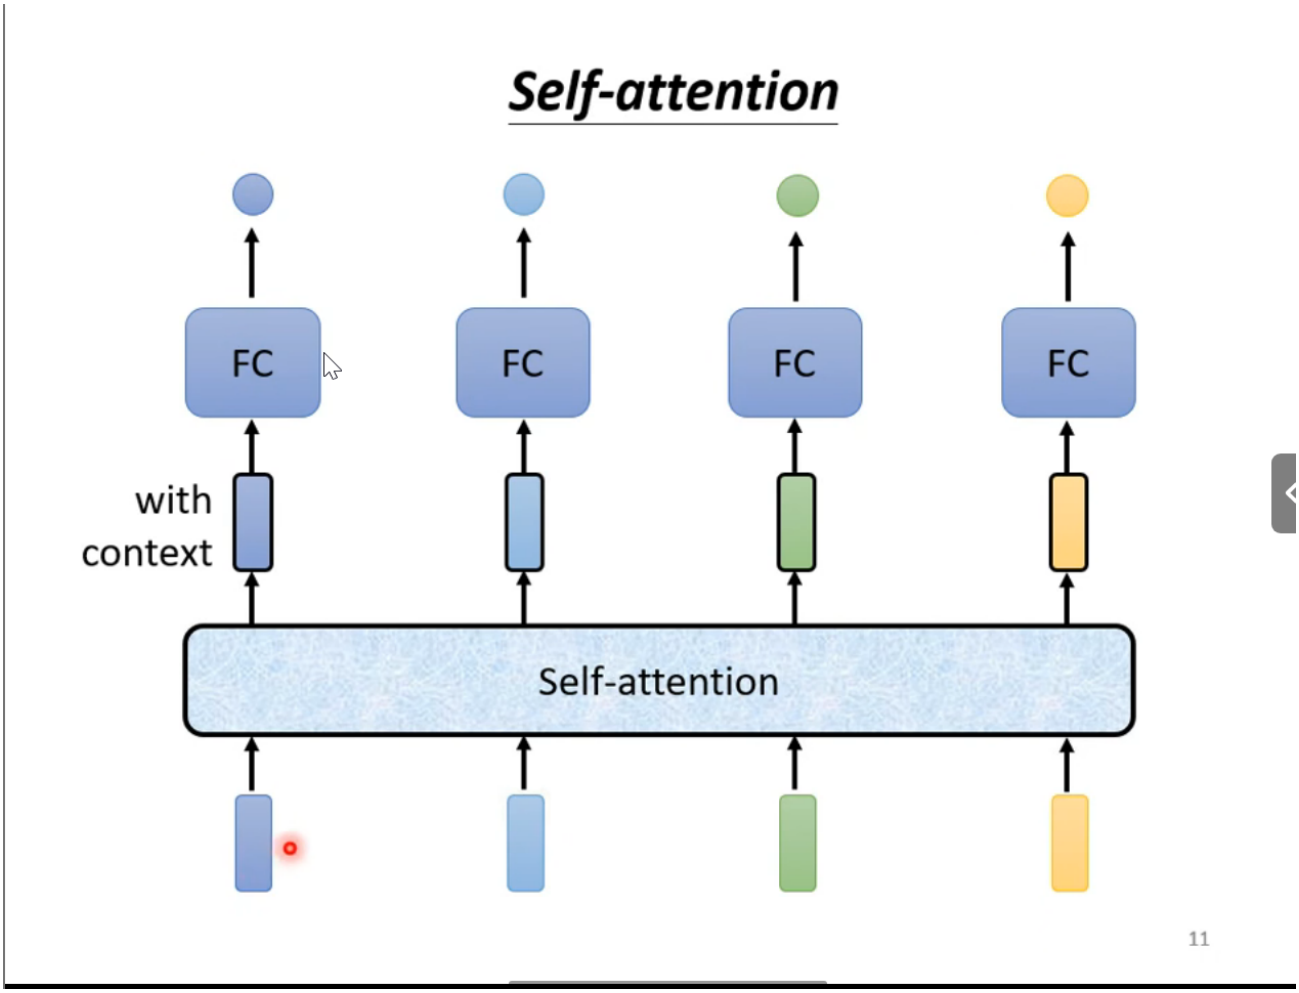

image-20250418130432286

工作原理

基本思想：自注意力允许模型在处理序列数据时，计算序列中每个位置与所有其他位置之间的关联性

三个关键向量：

- 查询向量$(Query, Q)$
- 键向量(Key, K)
- 值向量$(Value, V)$

计算步骤：

- 对输入序列中的每个元素，通过三个不同的权重矩阵生成Q、K、V向量
    - 使用三个不同的权重矩阵进行线性变换：
        - $Q = X \times W^Q$
        - $K = X \times W^K$
        - $V = X \times W^V$

      其中W^Q、W^K、W^V是可训练的参数矩阵
- 计算每个位置的查询向量(Q)与所有位置的键向量(K)的点积，获得**attention score（注意力分数）**

    - dot product本质上是测量两个向量之间相似度的方法。当两个向量方向相似时，点积值较大；方向相反时，点积为负；方向垂直时，点积为零
        - 查询向量(Q)相当于**“我想找什么信息”**
        - 键向量(K)相当于**“各个位置提供的信息类型”**
        - 点积结果表示**“这个位置提供的信息与我需要的匹配程度”**
- 对注意力分数进行缩放（除以键向量维度的平方根），**主要是方式后续的softmax被推入梯度极小的区域，防止梯度消失**
- 应用softmax函数（如归一化RELU也可以），将分数转换为概率分布
- 用这些概率加权求和所有位置的值向量(V)，最后算出来的值会被attention score最高的输入所**主导**
    - 值向量(V)决定位置包含的实际信息内容
    - Q-K点积：确定**“我应该关注哪里”**（计算相关性）
    - V的加权求和：确定**“我应该提取什么信息”（获取内容）**

Multi-head Self-attention（多头注意力）

要有多个查询向量Q，**不同的查询向量负责不同种类**的相关性

- 计算a^i与其它输入的关联性
    - 计算$b^{i,1}$
        - 根据$q^{i,1}$、$k^{i,1}$、$k^{j,1}$计算出$b^{i,1}$
    - 计算$b^{i,2}$
        - 根据$q^{i,2}$、$k^{i,2}$、$k^{j,2}$计算出$b^{i,2}$
    - 计算b^i
        - 使用$b^{i,1}$与$b^{i,2}$再乘上一个**权重矩阵**得到b^i，得到**attention score**
    - 后面的处理与前面类似

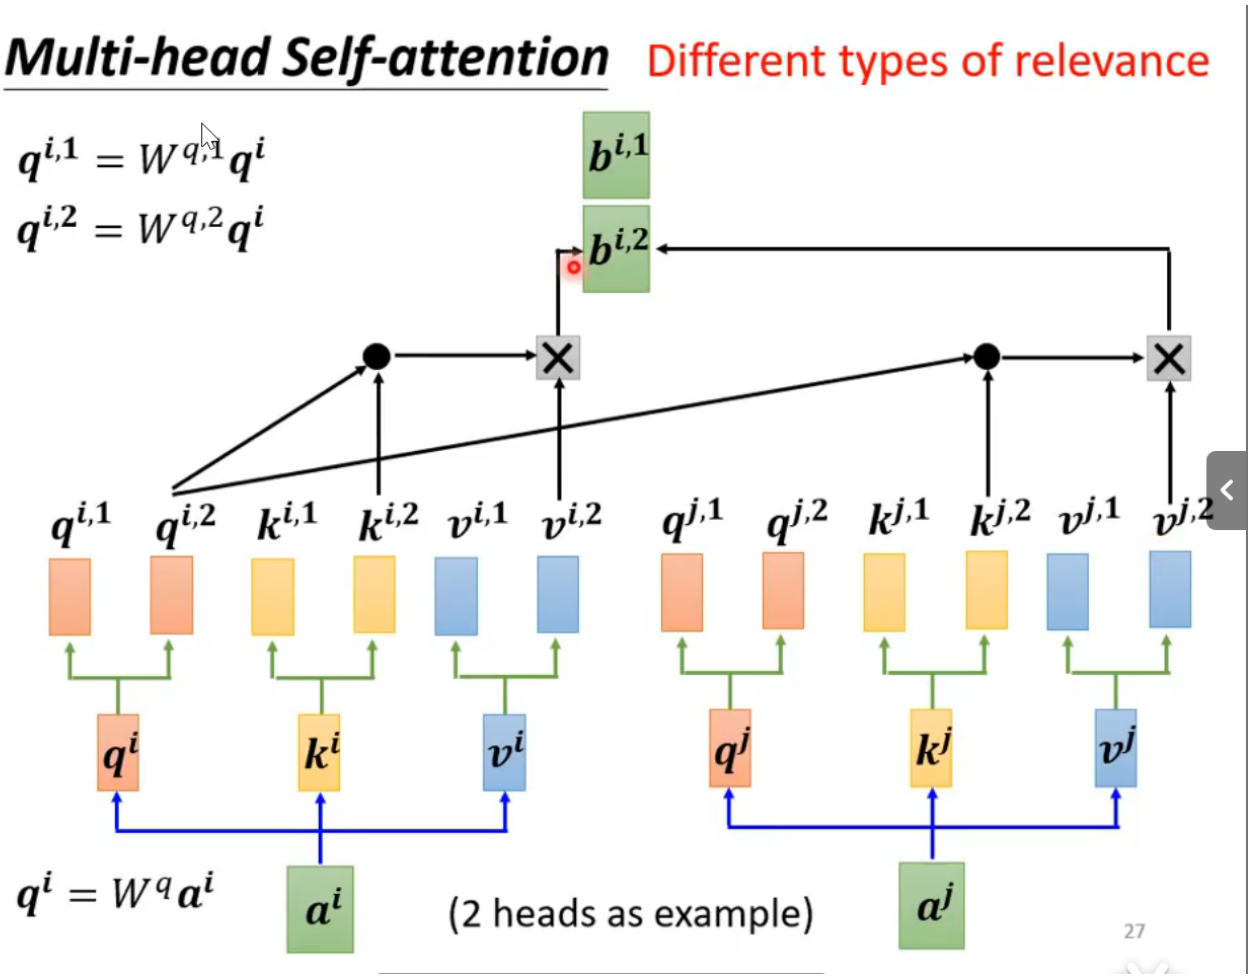

image-20250420112828589

Masked Multi-Head Self-Attention(多头掩码注意力)

自回归模型是一个词一个词生成的，也就是说**模型在做推理任务的时候是无法看到后面的词的**。

相应地，在训练的过程中，我们会给予模型正确的输出，但是我们并不希望模型看到它还未生成的词，也就是说假设训练数据是句子 `"A B C D"`，模型会一次性看到全部token，但通过掩码限制每个位置只能注意左侧。

自回归掩码（上三角掩码）：通常用于K、V矩阵

$$\begin{bmatrix} 1 & masked & masked & masked \\ 1 & 1 & masked & masked \\ 1 & 1 & 1 & masked \\ 1 & 1 & 1 & 1 \end{bmatrix}$$

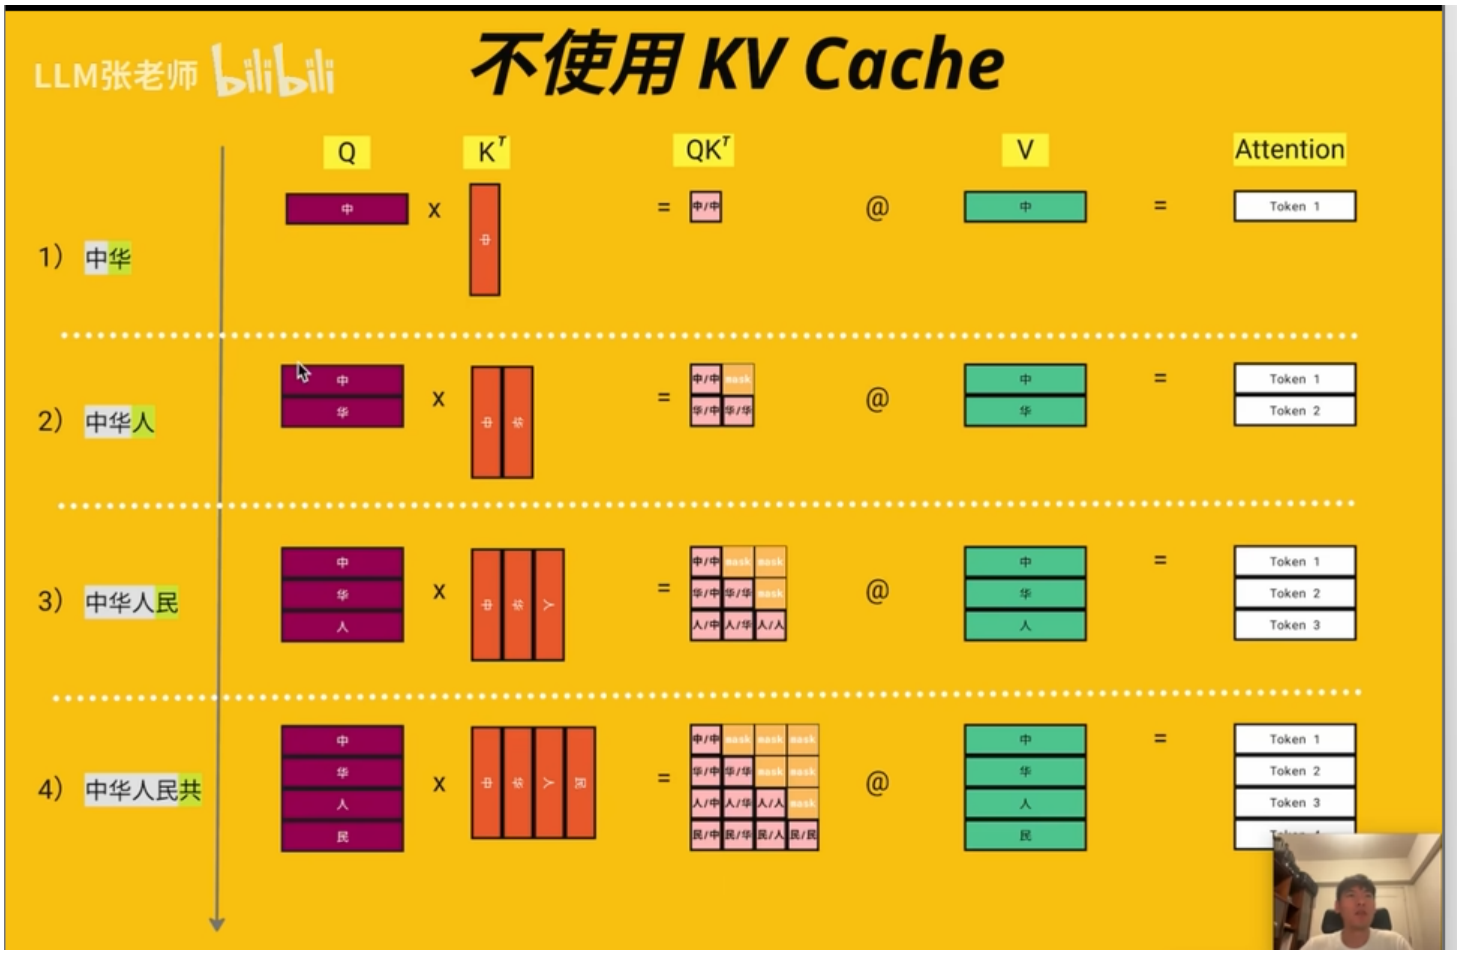

Word Embedding（词嵌入）

传统文本处理尝使用单热编码（**One-Hot Encoding**）来表示单词。但是这种表达方式**无法捕捉单词之间的语义关系**，不适合用来词的编码

- 因为每个单词表示的向量都是**正交**的
- 同时维度会非常大，会耗费计算资源

Positional Encoding

- **Self-attention**的局限：自注意力机制是“置换不变的”，即打乱输入序列顺序后结果不变，这对序列建模是不利的
- **序列顺序**的重要性：在语言和其他**序列**数据中，单词或令牌的顺序包含重要信息，影响意义

绝对位置编码的工作流程

1. 生成位置向量（**positional vector**），每个位置有**唯一**的位置向量
2. 把这个位置向量**直接**加到**对应位置**的输入**词嵌入向量**上

> Final_embedding = Token_embedding + Positional_encoding

绝对位置编码

给每个位置分配一个单独的向量

常用：可学习式、三角式

三角式

$$PE_{(pos,2i)} = sin(pos/10000^{2i/d_{model}}) PE_{(pos,2i+1)} = cos(pos/10000^{2i/d_{model}})$$

1. pos为绝对位置
2. $2i$为维度下标，$2i \leq d_{model}$
3. d_{model}为模型维度，也就是每个词或者位置会被编码为d_{model}维的向量

- 比如I am a kid
  - 绝对位置
    - I的pos为0
    - am的pos为1，其它以此类推
  - 维度下标（对于am，pos=1）
    - i=0
      - 第0维：$PE_{(1,0)} = sin(1/10000^{0/d_{model}})$
      - 第1维：$PE_{(1,1)} = cos(1/10000^{0/d_{model}})$
    - i=1
      - 第2维：$PE_{(1,2)} = sin(1/10000^{2/d_{model}})$
      - 第3维：$PE_{(1,3)} = cos(1/10000^{2/d_{model}})$

为每个位置分配一个向量，通过一个二维旋转矩阵引入相对位置信息

- 编码因子：$w_i = 10000^{\frac{2i}{d_{model}}}$
  - 指数级频率变化
    - 在表达式中，pos/w_i为频率，而编码因子以10000为底数，不同维度的波长呈现至少级变化，允许位置编码在**非常宽的频率范围内**分布，因为编码因子可以看作是指数函数（后续给出证明）
    - 这种特性**允许模型捕捉长距离的和短距离的依赖关系**（词和词之间），对于任意长度的序列都适用，有效解决了LSTM里面长序列遗忘的问题
  - 平滑频率变化
    - 模型需要处理高维特征，d_{model}越大，说明w_i的增长就越慢，从而导致$10000^{2i/d_{model}}$增长缓慢，因而相对于位置pos变化，$ pos/10000^{2i/d_{model}}$变化得更慢，导致频率变化变慢
    - 这种情况可以导致相邻位置编码差异较小，让模型能够捕捉到**位置连续性和顺序性**

三角式编码的特性

$$\begin{bmatrix} PE_{(pos+\Delta,2i)} \\ PE_{(pos+\Delta,2i+1)} \end{bmatrix} = \begin{bmatrix} cos(\Delta\theta_i) & sin(\Delta\theta_i) \\ -sin(\Delta\theta_i) & cos(\Delta\theta_i) \end{bmatrix} \begin{bmatrix} PE_{(pos,2i)} \\ PE_{(pos,2i+1)} \end{bmatrix}$$

位置$(\text{pos}+\Delta)$处的编码　　相对位置信息　　位置pos处的编码

其中：Δ为绝对位置之差，$\theta_i = \frac{1}{10000^{\frac{2i}{d_{model}}}}$

而

$$\begin{bmatrix} cos(\Delta\theta_i) & sin(\Delta\theta_i) \\ -sin(\Delta\theta_i) & cos(\Delta\theta_i) \end{bmatrix}$$

顺时针旋转$\Delta\theta_i$

是一个旋转矩阵，表示顺时针旋转$\Delta\theta_i$ **（与具体的位置pos无关）**

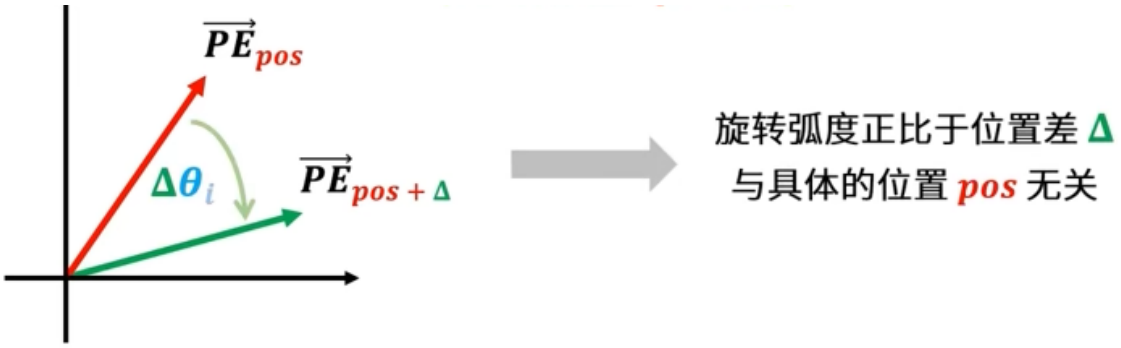

image-20250701224305593

下面我们来证明一下

$$\begin{aligned}\begin{bmatrix} PE_{(pos+\Delta,2i)} \\ PE_{(pos+\Delta,2i+1)} \end{bmatrix} &= \begin{bmatrix} sin((pos+\Delta)\cdot\theta_i) \\ cos((pos+\Delta)\cdot\theta_i) \end{bmatrix} \\ &= \begin{bmatrix} sin(pos\cdot\theta_i)cos(\Delta\cdot\theta_i)+cos(pos\cdot\theta_i)sin(\Delta\cdot\theta_i) \\ cos(pos\cdot\theta_i)cos(\Delta\cdot\theta_i)-sin(pos\cdot\theta_i)sin(\Delta\cdot\theta_i) \end{bmatrix} \\ &= \begin{bmatrix} cos(\Delta\theta_i) & sin(\Delta\theta_i) \\ -sin(\Delta\theta_i) & cos(\Delta\theta_i) \end{bmatrix} \begin{bmatrix} sin(pos\cdot\theta_i) \\ cos(pos\cdot\theta_i) \end{bmatrix} \\ &= \begin{bmatrix} cos(\Delta\theta_i) & sin(\Delta\theta_i) \\ -sin(\Delta\theta_i) & cos(\Delta\theta_i) \end{bmatrix} \begin{bmatrix} PE_{(pos,2i)} \\ PE_{(pos,2i+1)} \end{bmatrix}\end{aligned}$$

Transformer能够捕捉长短距离依赖的数学原因

已知：

$$\begin{aligned}w_i &= 10000^{2i/d_{model}} \\ \theta_i &= pos/10000^{2i/d_{model}} \\ &= pos/w_i\end{aligned}$$

- i小：w_i小，**频率高**，对应词向量低维度，θ_i对pos变化敏感，捕捉短距离依赖
- i大：w_i大，**频率低**，对应词向量高维度，θ_i对pos变化不敏感，对于长序列的词，位置编码的值不会变成0，例如$\Delta pos = 1000$，$\frac{1000}{10000} = 0.1$，能捕捉长距离依赖
- 如果w_i为10000，$sin(pos/10000)$需pos变化20000π才重复周期，出现相同编码值，**混淆文档开头和结尾的词**，但是在日常使用并不会出现如此长序列的词（这种方式也决定了它的**使用上限**）

相对位置编码

- **传统注意力分数**的计算是通过绝对位置编码注入到输入嵌入中，QK^T仅仅计算词的内容相关性，而忽略了**位置信息**，长序列中，绝对位置编码可能因**周期性重复导致混淆**
- **相对位置编码**不考虑**绝对位置**，在内积中融入相对位置**(query和key的位置差)**信息，让注意力得分**直接**感知到Q和K的位置差，考虑位置信息

相对位置编码来源于绝对位置编码，我们先来推导下绝对位置编码下Q和K的表达形式

$$q_i = W_q(x_i + p_i)k_j = W_k(x_j + p_j)$$

二者做内积

$$q_i^T k_j = (x_i + p_i)^T W_q^T W_k (x_j + p_j) = x_i^T W_q^T W_k x_j + x_i^T W_q^T W_k p_j + p_i^T W_q^T W_k x_j + p_i^T W_q^T W_k p_j$$

输入向量内积　　输入-位置交互项　　位置编码内积

假设位置信息和输入信息**相互独立**，上式可化成

$$q_i^T k_j = x_i^T W_q^T W_k x_j + p_i^T W_q^T W_k p_j = x_i^T W_q^T W_k x_j + \beta_{i-j}$$

相对位置项　　相对位置项

而β_{i-j}是偏置项，也就是**相对位置编码**，在多头注意力中，每个注意力头$head_h$都会分配**一组**偏置项β_{i-j}^h(why??/)

T5（可学习偏置）

引入**分桶处理**的思想：不同的位置差按照大小会被分配到**不同的桶内**

写代码再细学

ALibi（无需训练的线性偏置）

直接在QK内积上加上一个**不用训练的偏置项**，这个**偏置项**是位置差矩阵乘以m

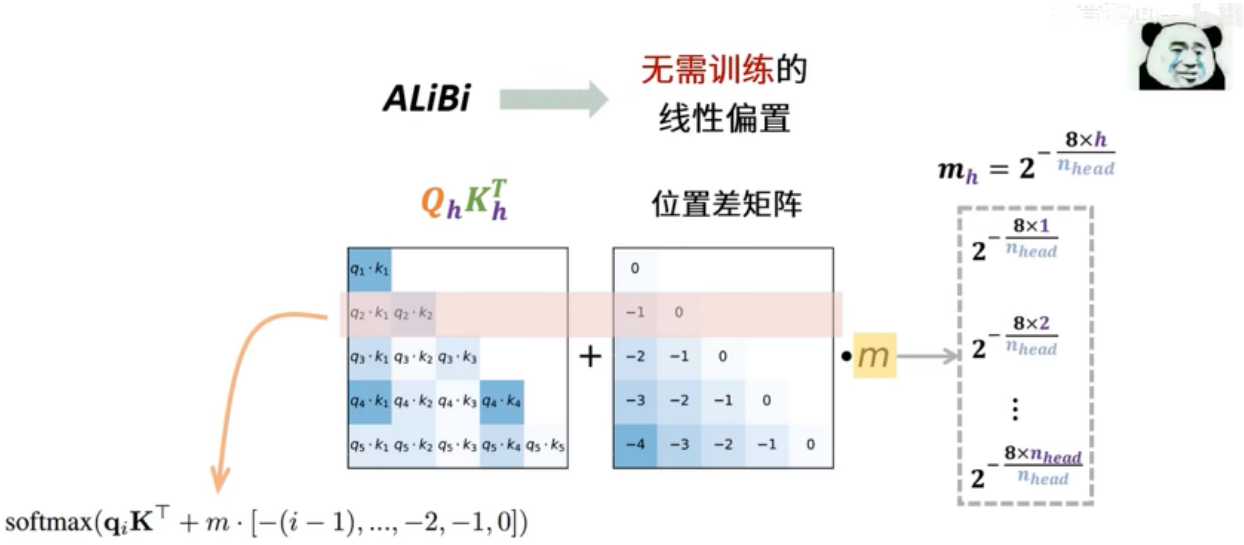

image-20250702192315616

其中：m是每个**注意力头的斜率**，$m_h = 2^{-\frac{8\times h}{n_h ead}}$，$n_{head}$为多头注意力的**头数**

$$m = \begin{bmatrix} 2^{-\frac{8\times 1}{n_h ead}} \\ 2^{-\frac{8\times 2}{n_h ead}} \\ \cdots \\ 2^{-\frac{8\times n_{head}}{n_h ead}} \end{bmatrix}$$

位置差矩阵是一个**下三角矩阵**，位置差矩阵$D_{ij} = -(i-j)$

最后**效果**是

$$softmax(q_iK^T + m \cdot [-(i-1), \ldots, -2, -1, 0])$$

RoPE（旋转位置编码）

结合了旋转位置编码和相对位置编码，**对每个Q和K左乘一个旋转矩阵**

在正常的注意力分数计算过程当中，我们是这么计算的

$$Attention\_score = q_m \cdot k_n^T$$

但是为了融入相对位置信息，我们让q和k分别乘上一个旋转矩阵

$$q^{rot} = q_m \cdot R_m k^{rot} = k_n \cdot R_n$$

所以：

$$\begin{aligned} q^{rot} \cdot k^{rot} &= q_m R_m R_n^T k_n^T \\ &= q_m R_m R_{-n} k_n^T \\ &= q_m R_{m-n} k_n^T \end{aligned}$$

可见其将**位置差信息融入**Q、K矩阵，同时由于**RoPE**的特性，模型可以**外推自己的上下文能力**并且还保持一定精度

1. **旋转矩阵周期性**

   对于过大的相对位置模型可能从未见过，但是由于**旋转矩阵具有周期性**，可以**使这个相对位置落在训练过的范围内**，从而增强泛化能力

2. **线性位置差**

无论绝对位置 m, n 多大，注意力分数仅依赖相对位置$m-n$

旋转矩阵的构造

- 对于维度为d的向量，RoPE将向量分成$d/2$组，每组应用一个**二维旋转矩阵，d一般都是偶数**

$$R_{\theta,m} = \begin{bmatrix} \cos m\theta_1 & -\sin m\theta_1 & 0 & \cdots & 0 \\ \sin m\theta_1 & \cos m\theta_1 & 0 & \cdots & 0 \\ 0 & 0 & \cos m\theta_2 & -\sin m\theta_2 & 0 \\ 0 & 0 & \sin m\theta_2 & \cos m\theta_2 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \end{bmatrix}$$

- 每组二维向量**独立乘以一个二维旋转矩阵**

$$\begin{bmatrix} x_i' \\ x_{i+1}' \end{bmatrix} = \begin{bmatrix} \cos m\theta_i & -\sin m\theta_i \\ \sin m\theta_i & \cos m\theta_i \end{bmatrix} \begin{bmatrix} x_i \\ x_{i+1} \end{bmatrix}$$

已知位置差$(m-n)$的旋转矩阵：

这里$\theta_i = \frac{1}{10000^{\frac{2i}{d_{model}}}}$

$$R_{m-n} = \begin{bmatrix} cos((m-n)\theta_i) & sin((m-n)\theta_i) \\ -sin((m-n)\theta_i) & cos((m-n)\theta_i) \end{bmatrix}$$

可以分解

$$R_n^T R_m = R_{m-n}$$

由旋转矩阵性质可知：

$$R_{-m} = R_m^T$$

再以内积形式呈现

$$(R_n q)^T R_m k = q^T R_{m-n} k$$

所以有

$$q_n^{rot} = R_n q k_m^{rot} = R_m k$$

可见其将**位置差信息融入**Q、K矩阵

KV Cache

- 主要应用于**推理阶段**
- 只存在于**解码器**中
- 目的是为了加速Q、K、V相乘速度
- 但也会加大内存占用

出现这个技术的原因是在**自回归模型**中，模型生成的是一个接一个的token。模型每次都要把预测输出的文字序列重新丢到模型里面计算，那么就要重新计算K、V，浪费计算资源。

比如：

- 我是
- 我是**中**
- 我是**中国**
- 我是**中国人**

如果不使用KV Cache进行缓存，模型就要重复计算“我是”这两个词的K、V

不适用KV Cache

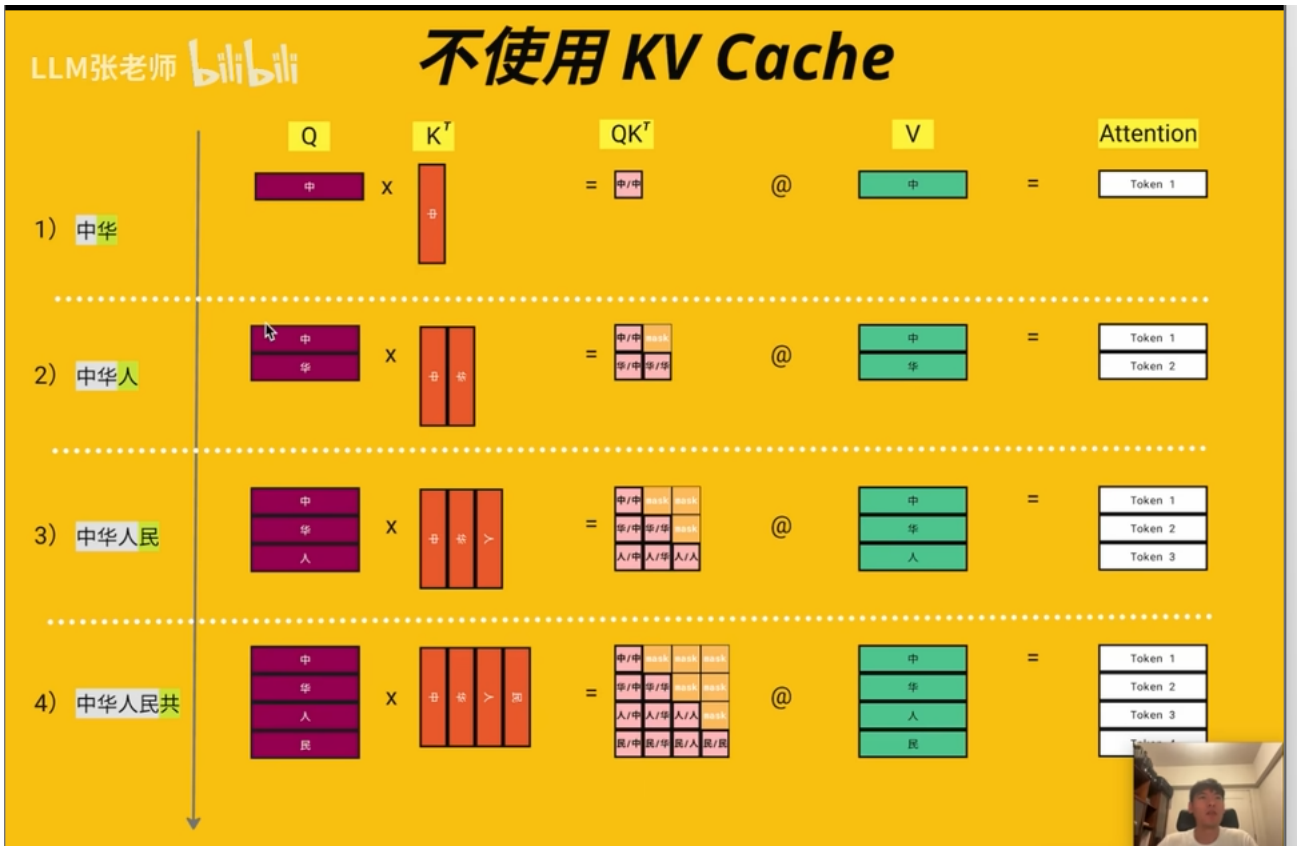

image-20250702191639250

使用KV Cache

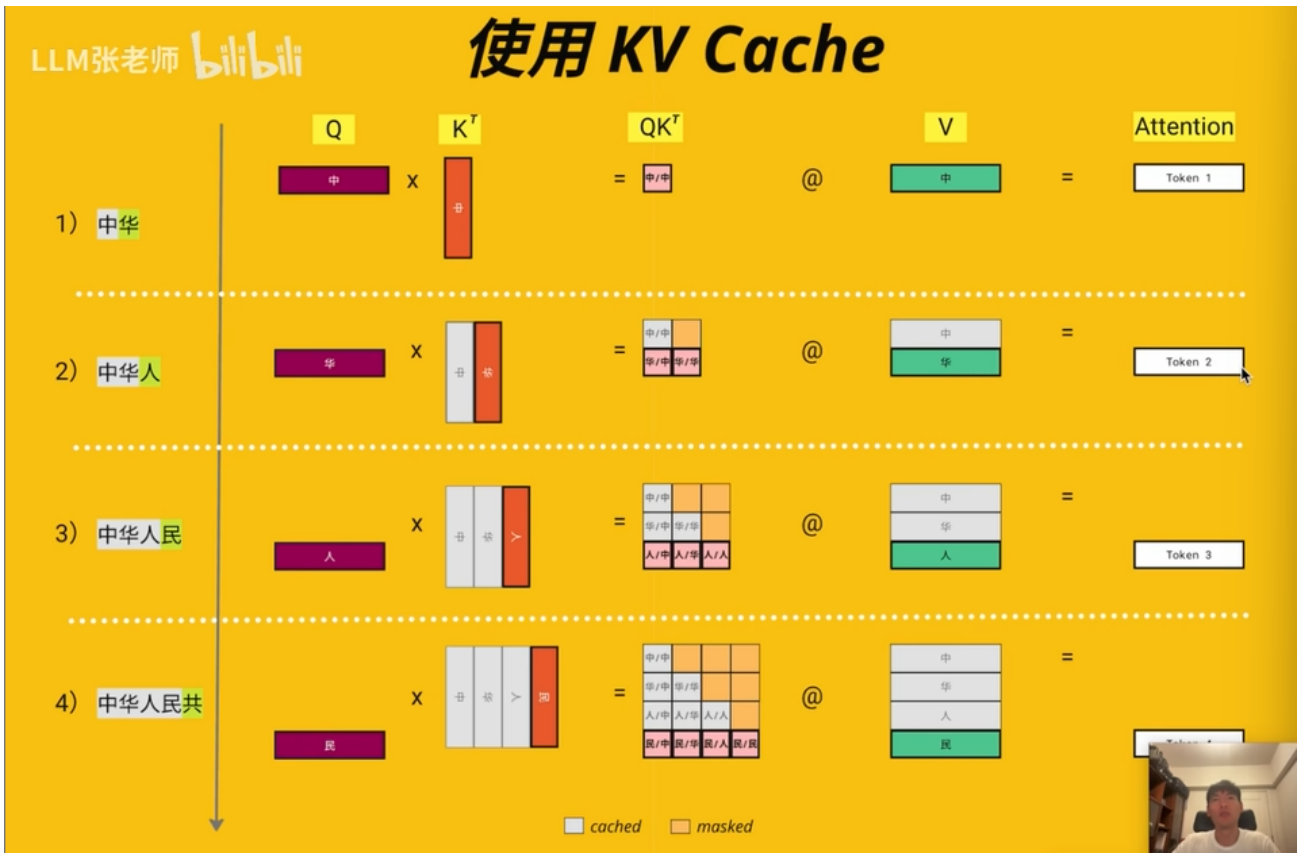

image-20250702191137599

Pre-Norm与Post-Norm

Pre-Norm（前归一化）和**Post-Norm（后归一化）**是Transformer模型中两种不同的归一化策略。他们的主要区别在于LN（Layer Normalization）的位置不同。

- 前归一化：在自注意力模块或者前馈网络之前进行层归一化，这种结构在训练时更容易且较为稳定
- 后归一化：在自注意力模块或者前馈网络之后进行层归一化。原始的Transformer使用的是这个，可以帮助稳定梯度，但需要更加谨慎地调节参数，如**学习率预热(warm-up)**。
- 目前比较主流的方法是**前归一化**，因为其训练起来比较稳定