

```
pip install -i https://mirrors.aliyun.com/pypi/simple/
```

```
nvidia-smi 查看NVIDIA GPU使用状态
```

```
lscpu 查看cpu信息
```

- P-core 物理核心数量20000
- E-core 能效核心数量

```
lscpu | grep cache 查看缓存
```

```
ls 查看文件
```

```
conda env list 查看环境
```

```
conda deactivate 退出环境
```

```
pwd 查看路径
```

```
conda create -n videollava python = 3.10 -y 创建videollava环境
```

```
mv oldname newname 重命名
```

```
conda remove --name myenv --all 删除myenv环境
```

```
rm -rf your_folder_name 删除文件夹
```

```
conda search qwen-vl-utils -c conda-forge 搜索qwen-vl-utils -c conda-forge
```

```
conda install -c conda-forge qwen-vl-utils=0.0.11 -y 安装
```

```
uptime 查看系统运行时间
```

```
uptime -s 查看系统启动时间
```

```
top 查看CPU使用率
```

- 1% CPU使用率
 - us 用户空间
 - sy 系统空间
 - id 空闲

```
history 查看命令历史
```

```
df -h 查看磁盘使用率
```

- tmfs 临时文件系统RAM
- /dev/nvme0n1p2 固态硬盘
- /dev/nvme0n1p1 固态硬盘
- efivarfs 固件变量

```
free -h 查看内存使用率
```

- total 总内存
- used 已用内存
- free 空闲内存
- buff/cache 缓冲/缓存
- available 可用内存

```
nvcc --version 查看cuda版本
```

tensorboard --logdir=./logs --port=6006 --bind_all

- --logdir : 指定する logging_dir
- --port : 指定する6006
- --bind_all : 指定する

ps aux

- ps Process Status
- a 表示するプロセスの属性
- u 表示するプロセスのユーザー
- x 表示するプロセスの環境変数

kill -9 1234 PID1234

ssh -L [ホスト]:[ポート]:[ホスト] [ユーザ]@[ホスト] 指定するホストに接続

sudo

sudo ufw status 指定するファイアウォールの状態を確認

sudo ufw allow/deny 8080 指定するポートを8080に許可/拒否

sudo ufw enable/disable 指定するファイアウォールを有効/無効にする

systemctl

sudo systemctl status nginx nginxのサービス状態を確認

sudo systemctl start/stop/restart redis redisのサービスを起動/停止/再起動

sudo systemctl enable/disable redis redisのサービスを有効/無効にする

tops 指定するプロセスのCPU使用率を確認

1 GOPS

- 1 GOPS = 10⁹OPS
- 1 POPS = 1000OPS

FP32

INT8

精度	PyTorch	ビット	対応するハードウェア
FP32	torch.float32	32	標準的なGPU
FP16	torch.float16	16	標準的なGPU
BF16	torch.bfloat16	16	Ampere GPU
TF(32)	torch.float32	19	NVIDIA Ampere GPU
INT8	torch.int8	8-bit	標準的なGPU
INT4	torch.int4	4-bit	標準的なGPU

FP16

FP32

精度	データ型	PyTorch
fp32	単精度浮動小数点	torch.float32
fp16	半精度浮動小数点	torch.float16
bf16	ブレイク半精度浮動小数点	torch.bfloat16
tf32	単精度浮動小数点(TF32)	torch.float32

```
# 8-bit quantization
quant_config = BitsAndBytesConfig(
    load_in_8bit=True,
    bnb_4bit_compute_dtype=torch.bfloat16
)
```

ブレイク半精度浮動小数点bfloat16と8-bit INT8-bit

CUDA

概要

- **CUDA Core**: GPU の計算能力を表す単位
- **SM (Streaming Multiprocessor)**
 - GPU の基本構成単位。SM は CUDA Core を含む。

メモリ

- **Global Memory**: CPU の RAM に相当するメモリ
- **Shared Memory**: SM 内で共有されるメモリ
- **Registers**: 各コアが持つ高速メモリ

実行

- **Kernel**: GPU で実行されるプログラム
 - GPU の各コアで並行実行される
- **Thread**: 実行される最小単位
 - **Thread**: 実行される最小単位
 - **Block**: SM 内で実行される単位
 - **Grid**: GPU 全体で実行される単位

CUDA ツール

- **CUDA**: GPU 計算のためのフレームワーク
- **cuDNN**: 深層学習のための最適化ライブラリ
- **cuFFT**: 高速フーリエ変換ライブラリ
- **cuBLAS**: 高速線形代数ライブラリ
- **NVCC**: CUDA コードを GPU 用にコンパイルするコンパイラ