

Pytorch

pytorch与tensorflow的区别

pytorch的特点

- 动态图模式
- 支持GPU加速

tensorflow的特点

- 静态图模式
- 支持GPU加速

datasets

```
from torchvision import datasets
```

使用

- `.dataset`
 - `root` 数据集根目录
 - `train` 训练数据集
 - `download` 是否下载
 - `transform` 数据转换

Dataset

在 `torch.utils.data` 模块中定义

使用 `torch.utils.data.Dataset` 类

- `__len__()` 返回数据集长度
- `__getitem__(idx)` 返回索引 `idx` 的数据

DataLoader

在 `torch.utils.data` 模块中定义 `Dataset` 类

- `batch_size` 每个batch的大小
- `shuffle=True` 是否在每个epoch中打乱数据
- `num_workers` 使用的进程数

| 参数 | 说明 |
|--------------------------|-----------------------------|
| <code>dataset</code> | 要加载的 <code>Dataset</code> 类 |
| <code>batch_size</code> | 每个batch的大小 |
| <code>shuffle</code> | 是否在每个epoch中打乱数据 |
| <code>num_workers</code> | 使用的进程数，CPU核数 |
| <code>drop_last</code> | 是否丢弃最后一个batch |
| <code>pin_memory</code> | 是否将数据pin到GPU内存 |

Transform

torchvision

| 函数 | 描述 |
|------------------------|----------------|
| ToTensor() | PIL 转换为 Tensor |
| Normalize(mean, std) | 归一化 |
| RandomCrop(size) | 随机裁剪 |
| RandomHorizontalFlip() | 随机水平翻转 |

神经网络

torch.nn.Function

$$\text{ReLU}(x) = \max(0, x)$$

- Relu
 - 输出范围 $[0, +\infty)$
 - 与 Sigmoid 类似
 - 不可导

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

- Tanh
 - 输出范围 $(-1, 1)$
 - 与 Sigmoid 类似
 - 不可导

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

- Sigmoid
 - 输出范围 $(0, 1)$
 - 与 Tanh 类似
 - 不可导

$$\text{GELU}(x) = x \cdot \Phi(x)$$

- GELU
 - ReLU 的改进
 - $\Phi(x)$ 是标准正态分布的累积分布函数
 - Transformer 使用

$$\text{Swish}(x) = x \cdot \sigma(\beta x)$$

- Swish
 - σ 是 Sigmoid, β 是缩放因子
 - 比 ReLU 更平滑
 - Transformer 使用

```
class Swish(nn.Module):
    def __init__(self,beta = 1.0):
        super().__init__()
        self.beta = beta

    def forward(self,x):
        return x * torch.sigmoid(self.beta * x)
```

$$\text{PreLU}(x) = \begin{cases} x & \text{if } x \geq 0 \\ ax & \text{if } x < 0 \end{cases}$$

- **PreLU**
 - 可微分
 - 在CNN中表现良好

损失函数

在 `torch.nn` 中

1. 均方误差 **MSE**

- 定义

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- 计算
- `nn.MSELoss()`

2. 交叉熵 **Cross-Entropy**

- 定义

$$\text{CE} = -\sum_{i=1}^n y_i \log(\hat{y}_i)$$

- 计算
- `nn.CrossEntropyLoss()`

优化器

在 `torch.optim` 中

初始化

1. 创建模型 `nn.Linear` 或 `nn.Conv2d`
2. 选择优化器 `optim.SGD` 或 `optim.Adam`
3. 训练循环
 - `optimizer.zero_grad()` 清零梯度
 - `loss.backward()` 反向传播
 - `optimizer.step()` 更新参数

SGD 优化器

- 参数
 - `model.parameters()` 模型参数
 - `lr` 学习率
 - `momentum` 动量
 - `dampening` 阻尼系数 0

- `weight_decay` L2 0

$$v_t = \beta v_{t-1} + (1-\beta) \frac{\partial J}{\partial w} \quad w = w - \alpha v_t$$

Adam

- 初始化
- 参数
 - `model.parameters()`
 - `lr`
 - `betas`
 - β_1
 - β_2
 - `eps` 0
 - `weight_decay` L2

1. 初始化

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$$

2. 更新

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t} \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t}$$

3. 更新

$$\theta_{t+1} = \theta_t - \frac{\alpha \cdot \hat{m}_t}{\sqrt{\hat{v}_t + \epsilon}}$$

RMSprop

- 初始化
- 参数
 - `model.parameters()`
 - `lr`
 - `alpha`
 - `eps` 0
 - `weight_decay` L2

$$v_t = \beta v_{t-1} + (1-\beta) \left(\frac{\partial J}{\partial w} \right)^2 \quad w = w - \alpha \frac{\frac{\partial J}{\partial w}}{\sqrt{v_t + \epsilon}}$$

初始化

初始化

```
from torch.optim import lr_scheduler
```

StepLR

| 参数 | 说明 |
|------------------------|------------|
| <code>optimizer</code> | 优化器 |
| <code>step_size</code> | 每隔多少epoch |
| <code>gamma</code> | 学习率衰减系数0.1 |

| | |
|------------|----------|
| last_epoch | 현재 epoch |
|------------|----------|

`scheduler.step()` 현재 scheduler

ReduceLROnPlateau (현재)

| key | value |
|----------------|----------------|
| optimizer | optimizer |
| mode | 'min' 또는 'max' |
| factor | factor |
| patience | epoch |
| threshold | threshold |
| threshold_mode | 'rel' 또는 'abs' |
| cooldown | epoch |
| min_lr | min_lr |
| verbose | verbose |

`scheduler.step(val_loss)` 현재

CosineAnnealingLR (현재)

| key | value |
|------------|-----------|
| optimizer | optimizer |
| T_max | epoch |
| eta_min | eta_min |
| last_epoch | 현재 epoch |

`scheduler.step()` 현재

Conv

`torch.nn` Convolutional layer

`$(in_channels,H,W)$`

- Convolutional layer
- Convolutional layer

args

- in_channels: RGB 3
- out_channels: Convolutional layer
- kernel_size: Convolutional layer
- stride: Convolutional layer
- padding: Convolutional layer

- `bias` 是否
- `dilation` 膨胀率
- `groups` 组数

计算公式 $H_{out} = \frac{H_{in} + 2 \times padding - dilation \times (kernel_size - 1) - 1}{stride}$

Transposed Conv

`torch.nn.ConvTranspose2d`

参数

初始化函数

参数

1. `in_channels` 输入通道数
2. `out_channels` 输出通道数
3. `kernel_size` 卷积核大小
4. `stride` 步长

属性

- `in_channels` 输入通道数
- `out_channels` 输出通道数
- `kernel_size` 卷积核大小
- `stride` 步长
- `padding` 填充
- `bias` 是否
- `out_padding` 输出填充



image-20250805130358084



image-20250805130421265

计算公式 $H_{out} = (H_{in} - 1) \times stride - 2 \times padding + kernel_size + output_padding$

Pool

`torch.nn`

参数

- `nn.MaxPool2d` 最大池化
- `nn.AvgPool2d` 平均池化
- `nn.AdaptiveMaxPool2d` 自适应最大池化

属性

- `kernel_size` 卷积核大小
- `stride` 步长
- `padding` 填充
- `dilation` 膨胀率

计算公式
$$H_{out} = \frac{H_{in} + 2 \times padding - dilation \times (kernel_size - 1) - 1}{stride}$$

Linear

`torch.nn` 线性层 $y = x \cdot W^T + b$

- `x`: 输入特征 `in_features`

参数

- `in_feature`: 输入特征数
- `out_feature`: 输出特征数
- `bias`: 偏置

线性层用于将输入特征映射到输出特征。

Flatten

`torch.nn` 展平层

- 将输入张量展平为一维向量 (batch_size, channels, height, width)
- 将输入张量展平为一维向量 (batch_size, channels * height * width)

Normalization

`torch.nn`

Batch Normalization

批归一化

类 `nn.BatchNorm1d`

- 参数

类 `nn.BatchNorm2d` 批归一化 (Batch Normalization)

- 参数 `[Batch_size, Channels, Height, Width]`
- 将输入张量展平为一维向量 **Batch**
- 将输入张量展平为一维向量 `Channels`

参数

- 参数
- 参数 `batch`
- 参数

Layer Normalization

层归一化

类 `nn.LayerNorm`

参数

- 参数
- 参数 **RNN/Transformer**

Group Normalization

nn.GroupNorm

nn.GroupNorm 是 PyTorch 中用于对输入张量进行组归一化的操作。

参数

- num_groups 组数
- num_channels 通道数
- affine 是否包含缩放和偏移

Upsample

nn.Upsample

nn.Upsample 是 PyTorch 中用于对输入张量进行上采样的操作。

参数

| 参数 | 类型 | 描述 |
|---------------|-------------|---|
| size | int tuple | 目标尺寸 (256, 256) 或 None 表示 scale_factor |
| scale_factor | float tuple | 缩放因子 (2, 3) 或 2 或 3 |
| mode | str | 插值模式: 'nearest', 'bilinear', 'bicubic', 'nearest' |
| align_corners | bool | 是否对齐角点: bilinear/bicubic 时为 False |

Dropout

torch.nn.Dropout 是 PyTorch 中用于对输入张量进行随机丢弃的操作。

.train() 开启 .eval() 关闭

Interpolate

torch.nn.functional.interpolate 是 PyTorch 中用于对输入张量进行插值的操作。

torch.nn.functional.interpolate 是 PyTorch 中用于对输入张量进行插值的操作。

参数

| 参数 | 类型 | 描述 |
|---------------|--|---------------------|
| size | (target_h, target_w) | 目标尺寸 |
| scale_factor | float (float, float) | 缩放因子 2.0 或 2 |
| mode | 'nearest', 'bilinear', 'bicubic', 'area' | 插值模式 |
| align_corners | bool | 是否对齐角点: True 表示对齐角点 |

使用

torch.nn.functional.interpolate 是 PyTorch 中用于对输入张量进行插值的操作。

- torch.utils.checkpoint
 - 使用

1. `checkpoint` `fn`
2. `checkpoint` `fn`

• `fn`

- `fn` `checkpoint`
- `**args` `checkpoint`

`fn`

```
import torch
import torch.nn as nn
from torch.utils.checkpoint import checkpoint

class BigModel(nn.Module):
    def __init__(self):
        super().__init__()
        self.layer1 = nn.Linear(1000, 1000)
        self.layer2 = nn.Linear(1000, 1000)
        self.layer3 = nn.Linear(1000, 1000)

    def forward(self, x):
        # checkpoint
        x = checkpoint(self.layer1, x) # checkpoint self.layer1(x)
        x = checkpoint(self.layer2, x)
        x = self.layer3(x) # checkpoint
        return x

## fn
model = BigModel()
inputs = torch.randn(32, 1000)
outputs = model(inputs)
loss = outputs.sum()
loss.backward() # checkpoint layer1 layer2
```

- `torch.utils.checkpoint_sequential` `Sequential`

• `fn`

- `functions` `Sequential`
- `input` `Sequential`
- `segments` `Sequential`
 - `nn.Sequential` `segments` `Sequential`
 - `segments` `segments`

`fn`

```
from torch.utils.checkpoint import checkpoint_sequential

model = nn.Sequential(
    nn.Linear(10, 10),
    nn.ReLU(),
    nn.Linear(10, 10),
    nn.ReLU(),
```

```

        nn.Linear(10, 10)
    )

    input_tensor = torch.randn(2, 10, requires_grad=True)
    ## 每个 chunk 跑20000 forward 再 checkpoint
    output = checkpoint_sequential(model, chunks=2, input=input_tensor)

```

训练

训练

```

## 训练
accumulation_steps = 4
## 训练
optimizer.zero_grad()

for i, (inputs, labels) in enumerate(data_loader):
    outputs = model(inputs)
    # 计算
    loss = criterion(outputs, labels)
    # 梯度累加
    loss = loss / accumulation_steps
    # 反向传播
    loss.backward() # 梯度累加

    if (i + 1) % accumulation_steps == 0:
        # 训练
        optimizer.step()
        # 梯度清零
        optimizer.zero_grad()

```

训练

- $\text{batch_size} = 36$

$$\nabla L_{\text{true}} = \frac{1}{32} \sum_{i=1}^{32} \nabla \text{loss}_i$$

- $\text{mini_batch} = 8$

$$\nabla L_{\text{accu}} = \sum_{j=1}^4 \left(\frac{1}{4} \cdot \frac{1}{8} \sum_{k=1}^8 \nabla \text{loss}_{jk} \right) = \frac{1}{32} \sum_{i=1}^{32} \nabla \text{loss}_i$$

训练

`torch.nn.utils` 梯度裁剪

梯度裁剪

`clip_grad_value_`

- 梯度裁剪
- `torch.nn.utils.clip_grad_value_`
 - `model.parameters()` 梯度

- clip_value 0.000000

0.000000 clip_grad_norm_ 0

- 0.000000 L2 0.000000
- torch.nn.utils.clip_grad_norm_
 - model.parameters() 0.000000
 - max_norm 0.000000 L2 0.000000

0.000000

pytorch 0.000000

```
class EarlyStopping:
    def __init__(self, patience=3):
        self.patience = patience
        self.best_loss = float('inf')
        self.counter = 0
    # 0.000000
    def __call__(self, val_loss):
        if val_loss < self.best_loss:
            self.best_loss = val_loss
            self.counter = 0
            return False
        else:
            self.counter += 1
            return self.counter >= self.patience
```

0.000000

0.00

0.000000

0.000000 int8 0.000000 float32

- torch.quantization 0.00 from torch.quantization import quantize_dynamic
 - model 0.000000
 - {nn.Linear, nn.LSTM} 0.000000
 - dtype 0.000000

0.000000 int8

- 0.00
 1. 0.000000
 2. 0.000000 fuse_modules 0.00
 - torch.quantization.fuse_modules
 3. 0.000000 qconfig 0.00
 - torch.quantization.get_default_qconfig
 - fbgemm 0.00x86 qnnpack 0.00ARM

```
model.qconfig = torch.quantization.get_default_qconfig('fbgemm')
```

4. `prepare`

- `torch.quantization.prepare()`
 - `inplace` `bool`

5. `forward`

6. `convert`

- `torch.quantization.convert`

####

```
model = MyModel()
model.eval()

## 1. 融合
model_fused = torch.quantization.fuse_modules(model, [['conv', 'relu']])

## 2. qconfig
model_fused.qconfig = torch.quantization.get_default_qconfig('fbgemm')

## 3. prepare
torch.quantization.prepare(model_fused, inplace=True)

## 4. 校准
with torch.no_grad():
    for data, _ in calibration_loader:
        model_fused(data)

## 5. convert
torch.quantization.convert(model_fused, inplace=True)
```

Quantization Aware Training (QAT)“量化感知训练”`FakeQuantize` 量化感知训练

- `QAT`
 1. 融合
 - `torch.quantization.fuse_modules`
 2. `qconfig` 设置 QAT
 - `torch.quantization.get_default_qat_qconfig`
 3. `prepare_qat`
 - `torch.quantization.prepare_qat()`
 4. `epoch`
 5. `convert` 量化
 - `torch.quantization.convert()`

####

```

model.train()
model_fused = torch.quantization.fuse_modules(model, [['conv', 'relu']])

## 1. 量化 QAT
model_fused.qconfig = torch.quantization.get_default_qat_qconfig('fbgemm')

## 2. 准备 QAT
torch.quantization.prepare_qat(model_fused, inplace=True)

## 3. 训练
for epoch in range(num_epochs):
    for data, target in train_loader:
        output = model_fused(data)
        loss = loss_fn(output, target)
        loss.backward()
        optimizer.step()

## 4. 验证和转换
model_fused.eval()
torch.quantization.convert(model_fused, inplace=True)

```

剪枝

torch.nn.utils.prune

剪枝方法

- `prune.l1_unstructured` **L1** 剪枝
 - 剪掉绝对值最小的 **L1**
 - 剪掉绝对值最小的 **0**
- `prune.random_unstructured` 随机剪枝
 - `module` 模块
 - `name` 名称
 - `amount`
 - `float` 比例
 - `int` 数量
- `prune.ln_structured` 层剪枝
 - 层
 - `amount`
 - `float` 比例
 - `int` 数量
 - `n` L-n
 - `dim` 维度
 - 0 通道
 - 1 核
- `prune.remove` 移除
 - `module` 模块
 - `name` 名称

剪枝后的模型需要设置 `mask=0` 来初始化剪枝后的模型

5/5

tensorboard

```
from torch.utils import SummaryWriter from torch.utils.tensorboard import SummaryWriter
```

- `tensorboard`, `tensorboardx`

```
from torch.utils.tensorboard import SummaryWriter
## 创建 SummaryWriter 对象

writer = SummaryWriter('C:/study/pytorch/logs')

## 使用 SummaryWriter

writer.close()
```

1. □□□□

- ```
o writer.add_scalar()
 ■ tag 00000
 ■ 00 train/loss 0 eval/loss 0000000000
 ■ scalar_value 00000000000000y0
 ■ global_step 00000000000000x0
```

2.

- `writer.add_graph()`
  - `graph`
  - `graph_options`

3.

- `writer.add_hparams()`
  - `hparams`
  - `hparams_proto`

**tqdm**

□□□□□□□□

```
from tqdm import tqdm
```

tqdm()

- `train_loader = DataLoader(...)`
- `desc` `train_loader.description`
- `total` `train_loader.total_size`
- `leave` `train_loader.leave_size`

- unit 每秒 it/s 每 batch/s
- ncols 每行

`trainer.set_postfix()` 打印训练信息

- 在 `train_bar.set_postfix(loss=f"{loss.item():.4f}")`
- 在 `train_bar`

```
train_bar.set_postfix({
 'loss': f"{loss.item():.4f}",
 'acc': f"{acc.item():.2%}" # 准确率
})
```

保存模型

- 保存模型

`torch.save(model.state_dict(), './model_weights.pth')`

- 加载模型

`model.load_state_dict(torch.load('./model_weights.pth'))`

- 保存模型和路径

`torch.save(model, path)`

- 加载模型

`model = torch.load(path)`

分布式

分布式

- `from torch.nn.parallel import DistributedDataParallel as DDP`
- `from torch.utils.data.distributed import DistributedSampler`
- `import torch.distributed as dist`
- `import torch.multiprocessing as mp`

分布式

1. 初始化

分布式训练需要GPU

2. 初始化

分布式训练需要GPU

3. `DDP` 初始化 `DistributedSampler`
4. `torch.multiprocessing.spawn`

分布式

- `loss.backward()` 反向传播梯度到 `.grad` 属性

- `optimizer.step()` 更新参数
- `optimizer.zero_grad()` 清空梯度
- 清空梯度并更新参数
- `torch.no_grad()` 防止梯度反向传播
- `.requires_grad_` 设置是否需要梯度反向传播
- `loss.item()` 返回标量值 **Python**
- `optim.zero_grad()` 清空梯度
- `optimizer.step()` 更新参数
- `loss.backward()` 反向传播
- `self.training` 或 `nn.Module` 的 `training` 属性为 `True` 表示训练模式，`False` 表示推理模式
- 数据预处理
- 数据增强
- `.permute()` 调整维度顺序 `.reshape()` 调整形状