

神经网络与深度学习

[本页PDF](#)

机器学习

什么是机器学习：通过算法使得机器能从大量数据中学习规律从而对新的样本做决策

机器学习三要素：模型、学习准则、优化

常见三类机器学习问题：监督学习、无监督学习、强化学习

随机梯度下降法：每次迭代只选择一个样本来更新网络参数

- 输入训练集、验证集、学习率 α
- 随机初始化
- 循环直到模型在验证集的错误率不再下降（或小于某一个阈值）
 - 对训练集样本进行随机排序
 - 遍历每一个样本
 - 根据选取的样本更新参数
- 输出模型参数 θ

机器学习模型的几个评价指标

预测结果为 $\hat{y}$ ，真实结果为 y

- 准确率：预测正确的样本占总样本比例

$$\mathcal{A} = \frac{1}{N} \sum_{n=1}^N I(y^{(n)} = \hat{y}^{(n)})$$

- 错误率：预测错误的样本占总样本比例

$$\begin{aligned}\mathcal{E} &= 1 - \mathcal{A} \\ &= \frac{1}{N} \sum_{n=1}^N I(y^{(n)} \neq \hat{y}^{(n)})\end{aligned}$$

- 精确率：预测为正例占真正是正例的比例

$$P = \frac{TP}{TP + FP}$$

- 召回率：真正是正例占被模型预测为正例的比例

$$R = \frac{TP}{TP + FN}$$

精确率和召回率详见[统计学习方法](#)

前馈神经网络

反向传播算法执行过程

- 输入训练集，验证集，学习率，正则化系数等
- 随机初始化网络参数
- 循环直到模型在验证集的错误率不再下降（或小于某一个阈值）
 - 对训练集样本进行重排序
 - 遍历每一个样本
 - 前馈计算每一层的净输入和激活值
 - 反向传播计算每一层梯度
 - 更新参数
- 输出模型参数

CNN

RNN

长程依赖问题：循环神经网络在时间维度上非常深，包括梯度消失和梯度爆炸，可以使用**循环边改为线性依赖关系和增加非线性**来改进。

- 梯度消失：网络层数很深且导数小于1，经过每一层网络后导数不断衰减，造成梯度衰减
 - 改进模型
- 梯度爆炸：网络层数很深且导数大于1，经过每一层网络后导数不断被放大，造成梯度爆炸
 - 使用权重衰减或梯度裁剪

网络优化与正则化

神经网络优化的改善方法有**网络优化和网络正则化**两大类

小批量梯度下降：每次选取K个样本对模型参数进行更新，影响其的主要因素有

- 批量大小K
- 学习率
- 梯度估计

参数初始化方法

- 预训练初始化
- 随机初始化
 - 将参数都初始化为0导致第一遍前向计算时中间值都相同，导致反向传播权重更新也相同，导致神经元没有区分性，称为**对称权重现象**
- 固定值初始化

网络正则化方法

- L1、L2正则化
- 权重衰减
- 早停
- Dropout
- 数据增强
- 标签平滑

不能在循环神经网络中的循环连接上直接应用丢弃法：这样会损害循环网络在时间维度上记忆能力，导致信息流断裂，模型无法理解长序列依赖关系

L1、L2正则化目标函数

$$\theta^* = \argmin_{\theta} \frac{1}{N} \sum_{n=1}^N L(y^{(n)}, f(x^{(n)}; \theta)) + \lambda l_p(\theta)$$

神经网络优化的改善方法

- 使用更有效的优化算法来提高梯度下降优化方法的效率和稳定性，比如动态学习率调整、梯度估计修正
- 使用更好的参数初始化方法、数据预处理方法来提高优化效率
- 修改网络结构来得到更好的优化地形，比如使用ReLU激活函数、残差连接、逐层归一化等
- 使用更好的超参数优化方法

RMSProp

维护梯度平方的累积变量 G_t ，梯度为 g_t

$$G_t = \beta G_{t-1} + (1 - \beta) g_t^2$$
$$\theta_t = \theta_{t-1} - \frac{\alpha}{\sqrt{G_t} + \epsilon} g_t$$

Momentum

维护一个速度变量 v_t

$$v_t = \beta v_{t-1} + (1 - \beta) g_t$$
$$\theta_t = \theta_{t-1} - \alpha v_t$$

Adam算法

- 结合了RMSProp和动量法

计算移动平均（一阶矩和二阶矩）

$$M_t = \beta_1 M_{t-1} + (1 - \beta_1) g_t$$
$$G_t = \beta_2 G_{t-1} + (1 - \beta_2) g_t^2$$

偏差修正

$$\hat{M}_t = \frac{M_t}{1 - \beta_1^t}$$
$$\hat{G}_t = \frac{G_t}{1 - \beta_2^t}$$

更新参数

$$\Delta \theta_t = - \frac{\alpha}{\sqrt{\hat{G}_t} + \epsilon} \hat{M}_t$$

逐层归一化

- 批量归一化（Batch Normalization）：不同样本的同一维度上进行归一化
- 层归一化（Layer Normalization）：同一样本的不同维度进行归一化
- 权重归一化

- 局部响应归一化

无监督学习

典型的无监督学习问题分类

- 无监督特征学习
- 密度估计
- 聚类

主成分分析

- 优化函数：

第一主成分优化问题

$$\max_{w_1} w_1^T \Sigma w_1 \text{ s.t. } w_1^T w_1 = 1$$

第k主成分优化问题

\$\$

$$\begin{aligned} \max_{w_k} \quad & w_k^T \Sigma w_k \\ \text{s.t.} \quad & w_k^T w_k = 1, \quad w_k^T w_j = 0 \ (j = 1, \dots, k-1) \end{aligned}$$

\$\$

- 求解过程：使用拉格朗日乘子法，对 w_1 求导，令导数为0

线性编码

- 表达式
 - 输入样本 x 可以由基向量 A 和字典 Z 表示
 - 其中，基向量 $A = [a_1, \dots, a_m]$ ，编码向量是 $Z = [z_1, \dots, z_m]^T$

解码

$$x = \sum_{m=1}^M z_m a_m = AZ$$

编码

$$z = \sum_{m=1}^M x_m a_m = A^T x$$

稀疏编码

- 目标函数
 - 其中 ρ 是稀疏性衡量函数， η 是一个超参数，用来控制稀疏性的强度

$$\mathcal{L}(A, Z) = \sum_{n=1}^N (||x^{(n)} - Az^{(n)}||^2 + \eta \rho(z^{(n)}))$$

- 训练过程

1. 固定基向量 A ，对于每个输入 $x^{(n)}$ ，计算其对应的最优编码

$$\min_{z^{(n)}} \|x^{(n)} - Az^{(n)}\|^2 + \eta\rho(z^{(n)}), \forall n \in [1, N]$$

2. 固定上一步得到的编码 $\{z^{(n)}\}_{n=1}^N$ ，计算其最优的基向量

$$\min_A \sum_{n=1}^N (\|x^{(n)} - Az^{(n)}\|^2) + \lambda \frac{1}{2} \|A\|^2$$

编码器

自编码器

- 分为编码器和解码器
- 学习目标是重构错误（最小化重构误差）
- 和主成分分析在学习目标上完全一致：最小化重构误差
 - 在特定条件下，两者是同构的
 - 自编码器是主成分分析的**非线性泛化**

稀疏自编码器

- 目标函数
 - 其中 W 是自编码器中的参数
 - 不仅要求还原输入，还需要学习到稀疏且有意义的特征表示，且引入正则化进行参数惩罚


$$\mathcal{L} = \sum_{n=1}^N \|x^{(n)} - x'^{(n)}\|^2 + \eta\rho(z^{(n)}) + \lambda \|W\|^2$$

堆叠自编码器

- 将编码器进行逐层堆叠，训练一个深度的自编码器
- 采用**逐层训练**的方式更新参数


降噪自编码器

- 思想：通过引入噪声来学习更鲁棒性的数据编码，并提高模型的泛化能力
- 结构：在原始输入 x 中引入噪声，交由编码器还原
- 学习目标：要求网络能够对输入样本进行去噪，从含有噪声的样本中恢复原始数据



变分自编码器

- 结构:



- 目标函数: 最小化KL散度

$$\phi^* = \arg \min_{\phi} \text{KL}(q(z|x; \phi), p(z|x; \theta))$$

模型独立的学习方法

- 集成学习
- 协同学习
- 多任务学习
- 迁移学习
- 终身学习
- 元学习

注意力机制

组成部分

- 打分函数
- 提取机制

- 聚合机制

四种注意力机制

- 软性注意力：通过计算相似度作为权重对输入加权求和，计算完相似度之后一般用softmax
 - 打分函数： $s(x, q)$ ，对输入 x 和查询 q 计算相似度
 - 信息提取： $s(x, q) \cdot x$ ：用相似度作为连续权重对输入进行加权
- 硬性注意力：只选取相似度最高的那个输入
 - 打分函数： $I[s(x, q); \lambda]$ ，结合重参数技巧或阈值判断
 - 信息提取：只选取相似度最高的那个输入
- 键值对注意力：将输入拆分为 k 用于计算相似度， v 用于存储实际内容
 - 打分函数： $s(k, q)$ ，仅用 k 和 v 计算匹配度
 - 信息提取： $s(k, q) \cdot v$ ，用 k 和 q 的相似度加权对应的 v
- 多头注意力：将Query、Key、Value通过不同线性投影拆分为 h 组
 - 打分函数： $s(k_i, q_i)$
 - 信息提取： $s(k_i, q_i) \cdot v_i$ ，之后进行拼接

	软性注意力机制	硬性注意力机制	键值对注意力机制	多头注意力机制	
打分函数	$s(x, q)$	$I[s(x, q); \lambda]$	$s(k, q)$	$s(k, q_i)$	
信息提取机制	$s(x, q) \cdot x$	$argmax$	$s(k, q) \cdot v$	$s(k, q_i) \cdot v$	
聚合机制	加和	$argmax$	加和	拼接, 加和	

image-20260520105930741

Transformer的注意力机制是**基于软性注意力的键值对模式**

自注意力计算过程




图 8.4 自注意力模型的计算过程

自注意力机制

当神经网络要处理变长的输入序列时，通常使用循环网络或者卷积网络进行编码得到一个相同长度的输出序列

建立非局部的依赖关系

- 全连接模型
- 自注意力模型

概率图模型

贝叶斯网络（有向图模型/信念网络）

- 局部马尔可夫性质：每个随机变量在给定父节点的情况下，条件独立于它的非后代节点

必考

$$p(a, b, c) = p(a)p(b|a)p(c|a, b)$$

$$p(x_1, \dots, x_7) = p(x_1)p(x_2)p(x_3)p(x_4|x_1, x_2, x_3)p(x_5|x_1, x_3)p(x_6|x_4)p(x_7|x_4, x_5)$$

总结

:::tabs

@tab:active 第二章

机器学习三要素，常见三类机器学习问题

随机梯度下降法步骤

机器学习几个评价指标

反向传播算法执行过程是什么

什么是长程依赖问题、梯度消失、梯度爆炸，分别如何改进

神经网络优化的改善方法有哪些

什么是小批量梯度下降，影响其的主要因素有哪些

参数初始化方法有哪些，为什么神经网络不能初始化参数为0，会产生什么现象

网络正则化方法有哪些，L1、L2正则化目标函数

为什么不能在循环神经网络中的循环连接上直接应用丢弃法

神经网络优化的改善方法有哪些

几种常用的逐层归一化方法

@tab 第三章 典型的无监督学习问题可以分为哪几类

模型独立的学习方法有哪些

线性编码表达式 稀疏编码目标函数和训练过程